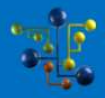

Engenharia de Dados com Hadoop e Spark

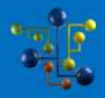

Bem-vindo(a)

Instrutores

Data Science Academy phelipe.utsempreboni@outlook.com 5c8a62005e4cde1acb8b45a3

Data Science Academy

A Data Science Academy (DSA) é um portal de ensino online especializado em Big Data, Machine Learning, Inteligência Artificial, Desenvolvimento de Chatbots, Blockchain e tecnologias relacionadas.

Nosso objetivo é fornecer aos alunos conteúdo de alto nível por meio do uso de computador, tablet ou smartphone, em qualquer lugar, a qualquer hora, 100% online e 100% em português.

Instrutores Data Science Academy

Data Science Academy phelipe.utsempreboni@outlook.com 5c8a62005e4cde1acb8b45a3

No Brasil e no Mundo

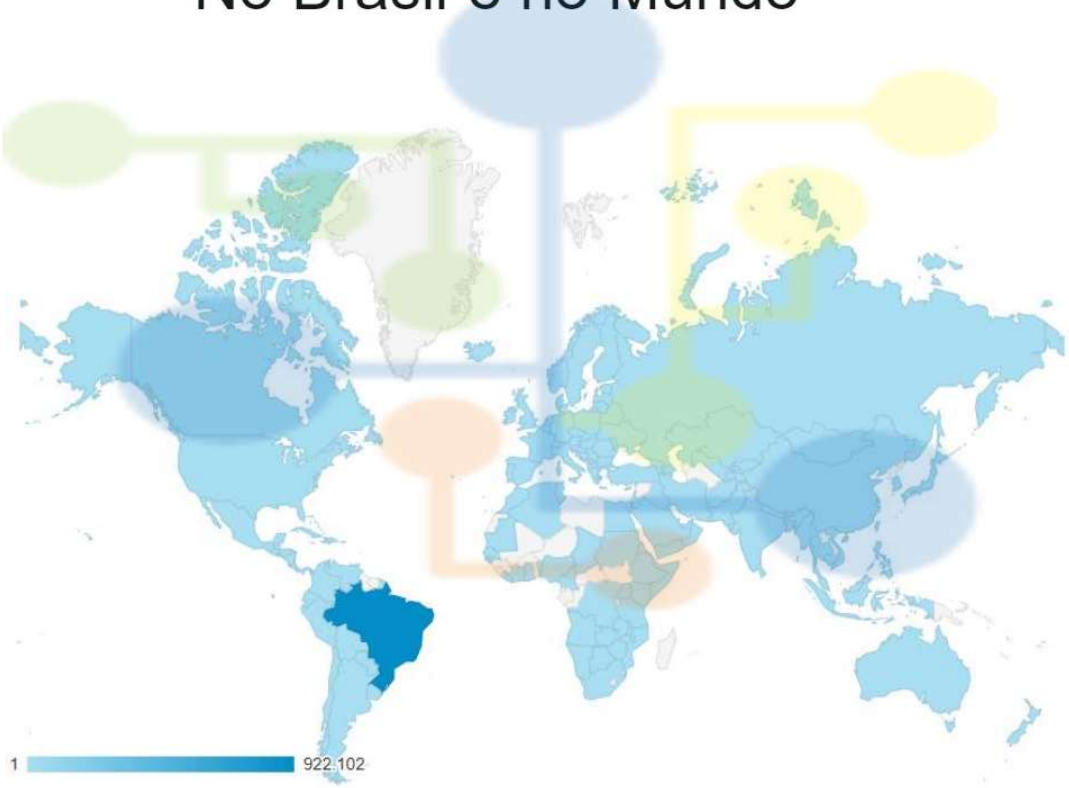

Engenharia de Dados com Hadoop e Spark

Engenharia de Dados com Hadoop e Spark

Engenharia de Dados com Hadoop e Spark

O que você vai aprender neste curso?

- Conceitos e definições de Big Data, Hadoop, Ecossistema Hadoop e Spark
- Como planejar, instalar e configurar um cluster Hadoop
- Como planejar, instalar e configurar o Ecossistema Hadoop (Hive, Hbase, Zookeeper, Flume, Oozie, Ambari, Sqoop, Spark e Storm)
- Configuração e utilização do HDFS e configurações avançadas do cluster Hadoop
- Administração e Manutenção do Hadoop e Spark

Engenharia de Dados com Hadoop e Spark

O que você vai aprender neste curso?

- Machine Learning com Apache Mahout
- Importação/exportação de dados e ETL com Sqoop
- Principais distribuições Hadoop do mercado: Cloudera e Hortonworks
- Infraestrutura de Big Data
- Análise de Big Data

Engenharia de Dados com Hadoop e Spark

E quais são os pré-requisitos?

- Curso Big Data Fundamentos 2.0
- Conhecimentos básicos de sistema operacional Linux (desejável)
- Conhecimentos básicos de linguagem de programação (desejável)
- Muita vontade de aprender e entrar no mundo do Big Data (mandatório)

Engenharia de Dados com Hadoop e Spark

Benefícios em realizar este curso

São muitos os benefícios em realizar este curso:

Big Data é uma das áreas que mais crescem atualmente. Há um déficit de profissionais no mercado e estima-se que até 2020 o mercado precisará de mais de 200 mil profissionais habilitados em Big Data.

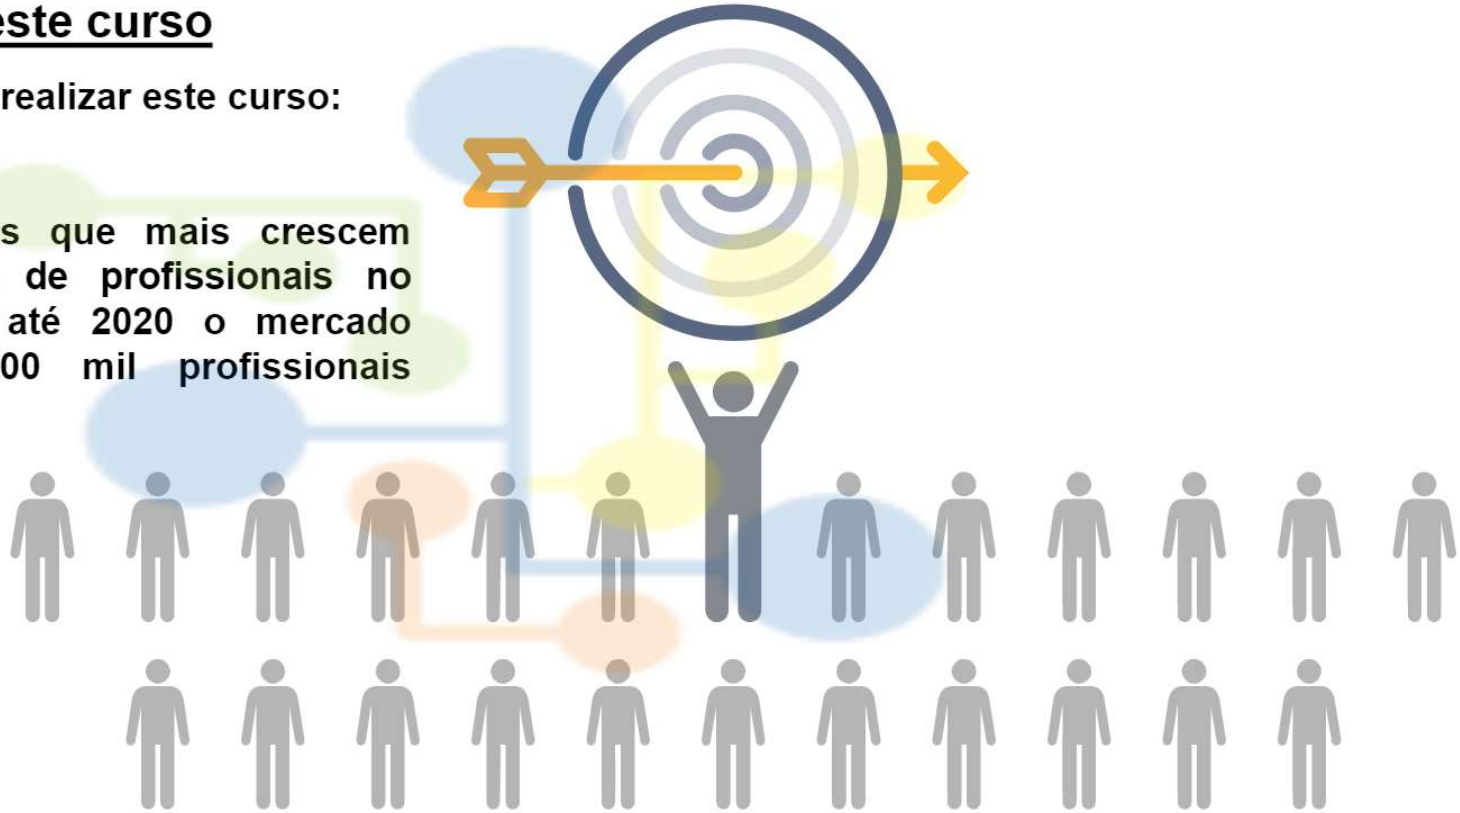

Engenharia de Dados com Hadoop e Spark

Benefícios em realizar este curso

São muitos os benefícios em realizar este curso:

Hadoop é a tecnologia base da infraestrutura de Big Data, que está revolucionando o mundo como o conhecemos. Ele permite a análise de grandes volumes de dados para tomada de decisão.

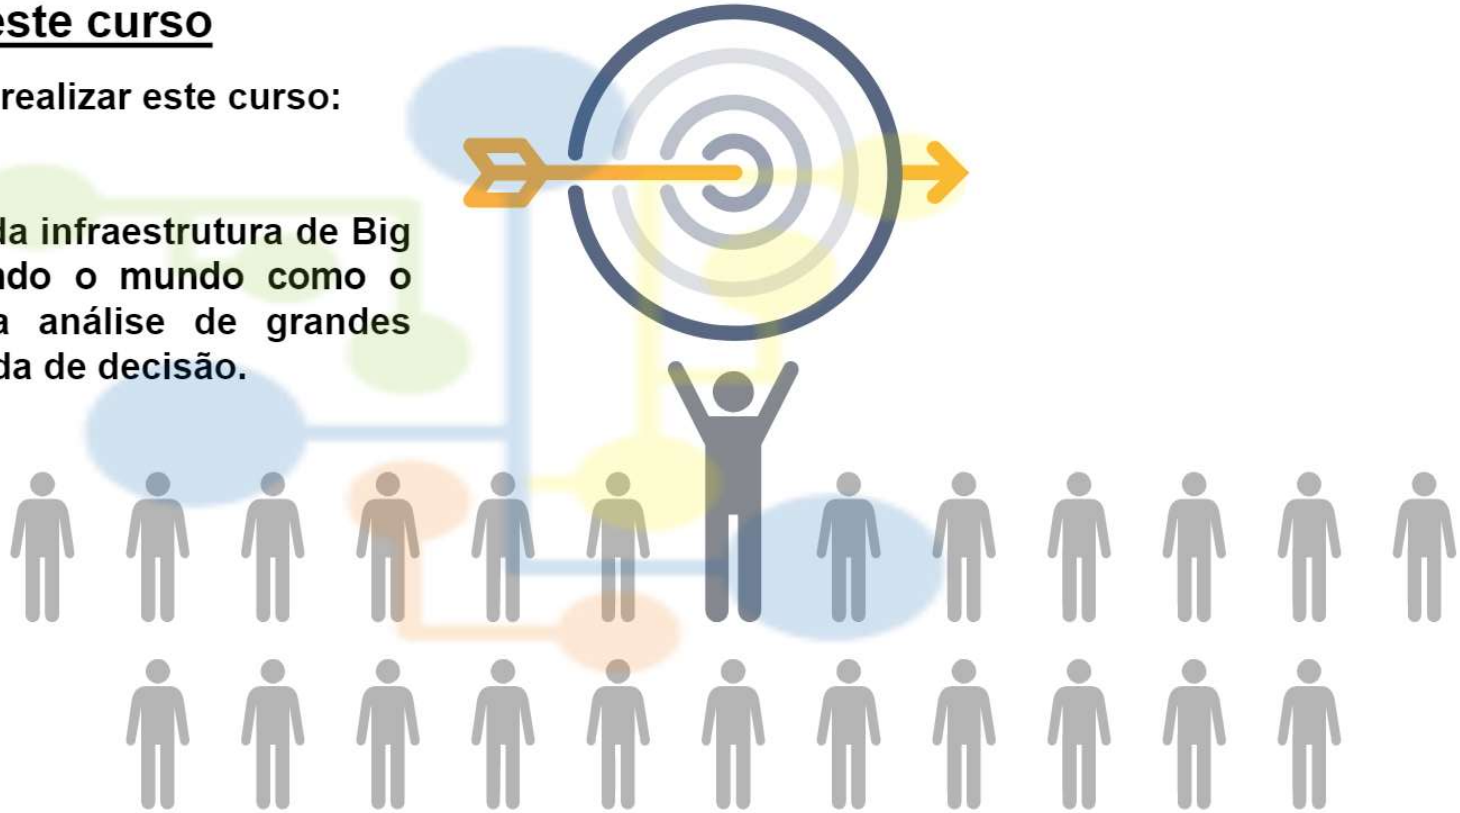

Engenharia de Dados com Hadoop e Spark

Benefícios em realizar este curso

São muitos os benefícios em realizar este curso:

Conhecimento de Hadoop é um dos skills mais procurados por recrutadores de profissionais de Big Data.

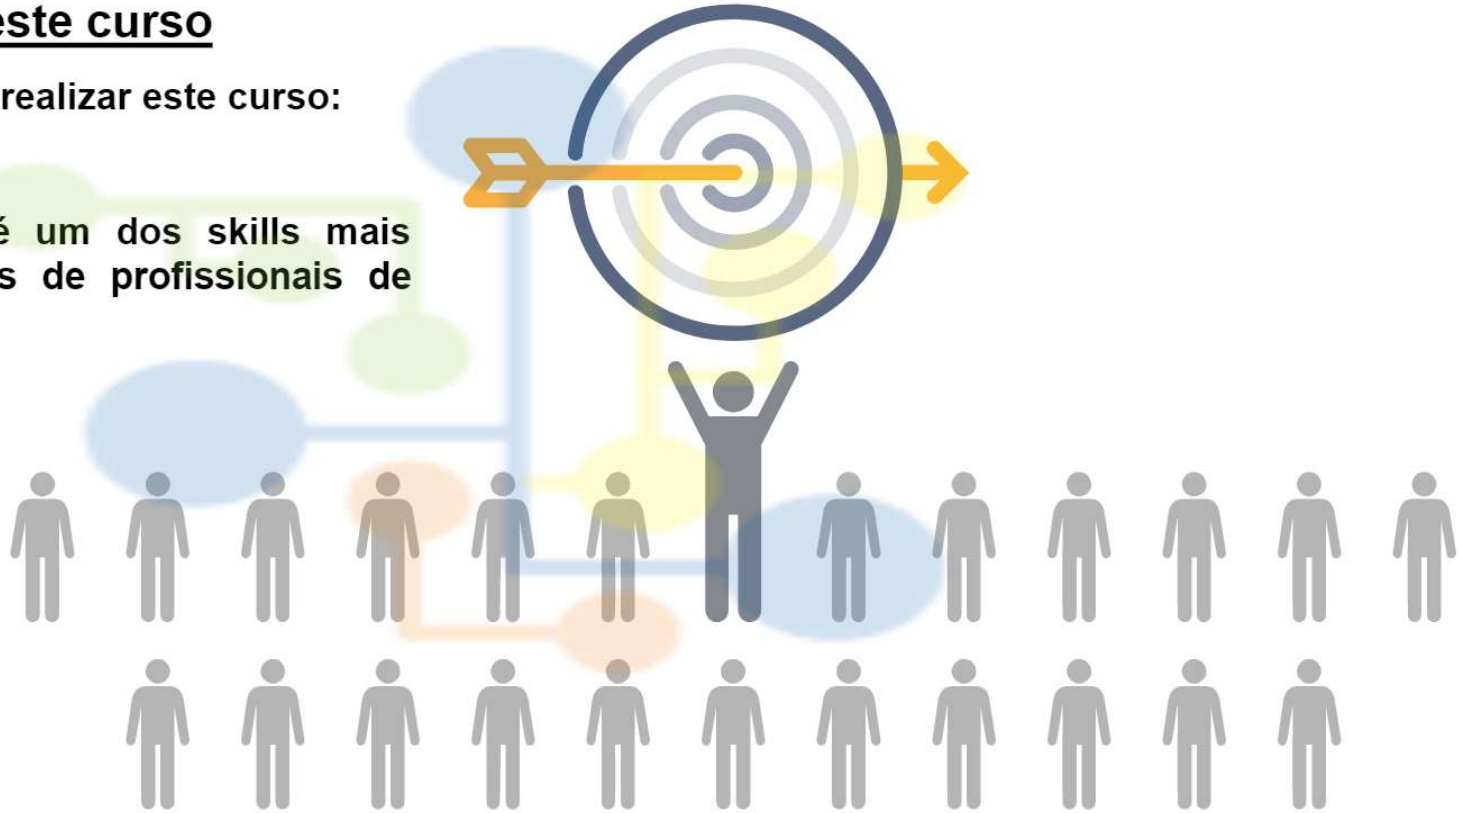

Engenharia de Dados com Hadoop e Spark

Benefícios em realizar este curso

São muitos os benefícios em realizar este curso:

O Hadoop permite a mudança de paradigma de bancos de dados tradicionais, para um framework de dados versátil, adaptável e veloz.

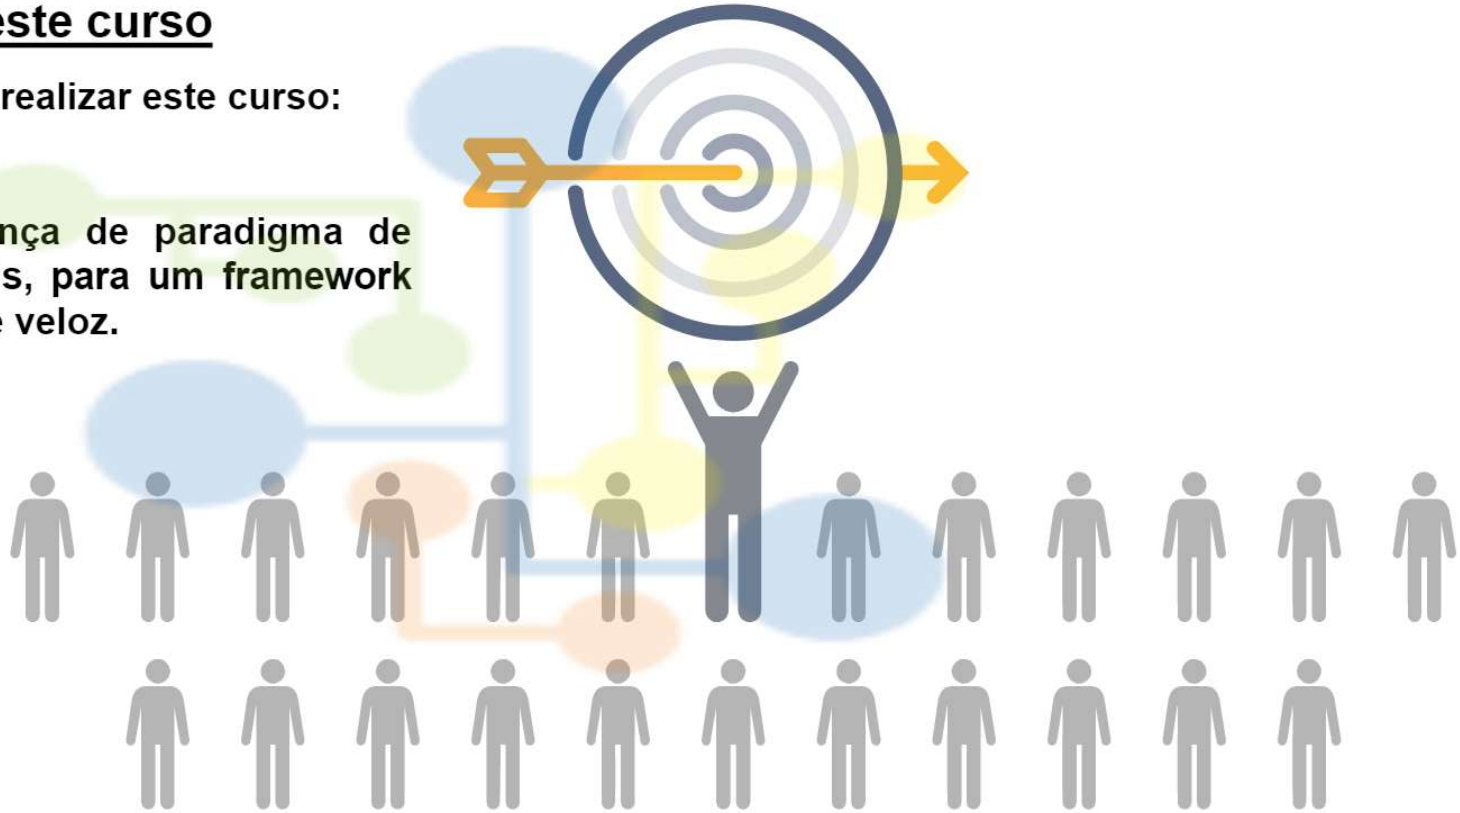

Engenharia de Dados com Hadoop e Spark

Estrutura do Curso

Para tornar sua experiência de aprendizagem ainda mais completa, você terá quizzes e labs ao longo de todos os capítulos.

Engenharia de Dados com Hadoop e Spark

Estrutura do Curso

Você também terá acesso e poderá fazer o download dos e-books com todo o passo-a-passo de cada lab realizado ao longo do curso.

Engenharia de Dados com Hadoop e Spark

Estrutura do Curso

Fique tranquilo se você não possui experiência em sistema operacional Linux. Tudo será explicado passo a passo.

Engenharia de Dados com Hadoop e Spark

Mini-Projetos

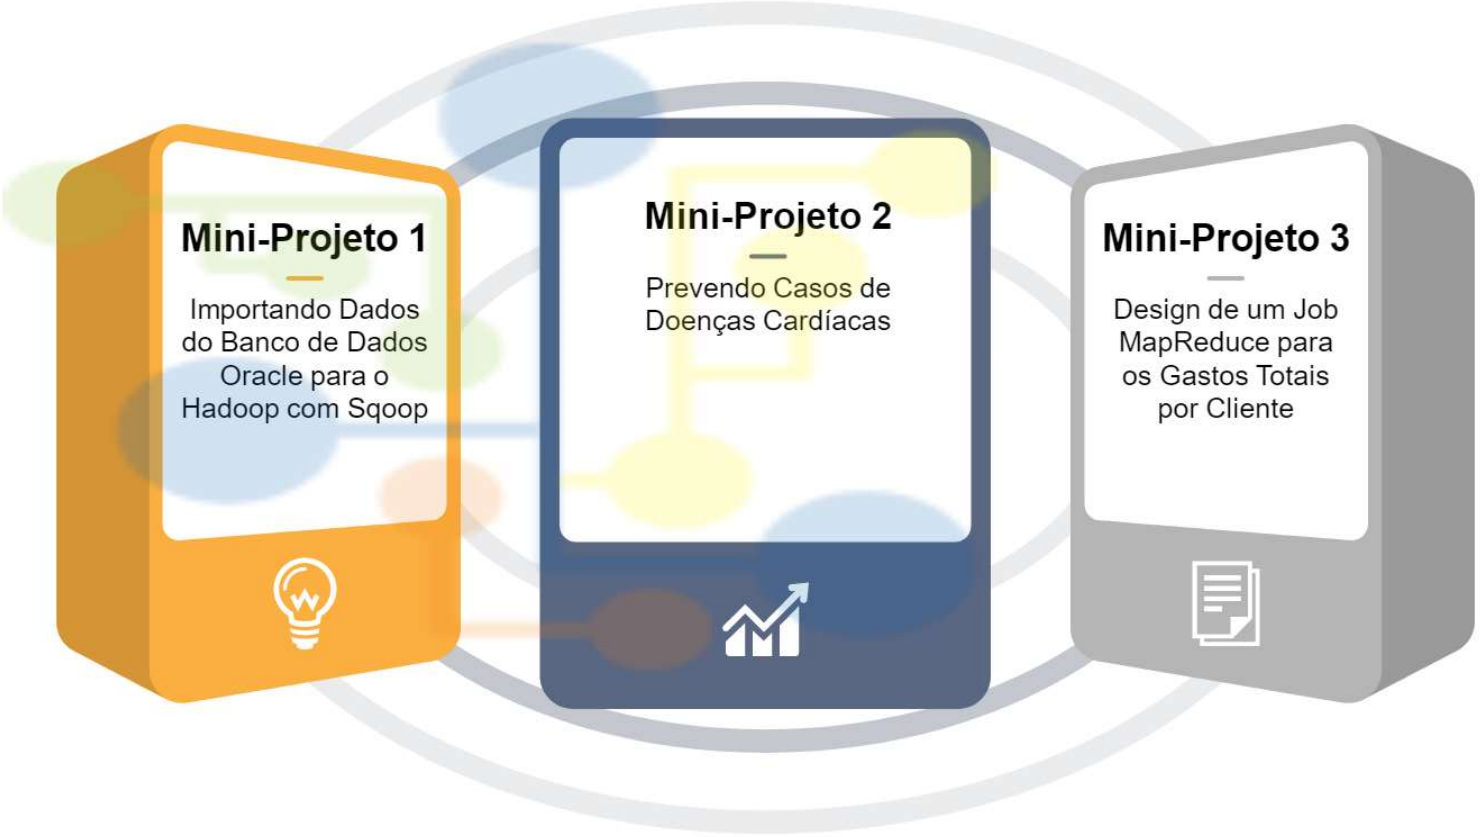

Engenharia de Dados com Hadoop e Spark

Projetos com Feedback

Engenharia de Dados com Hadoop e Spark

Avaliação Final

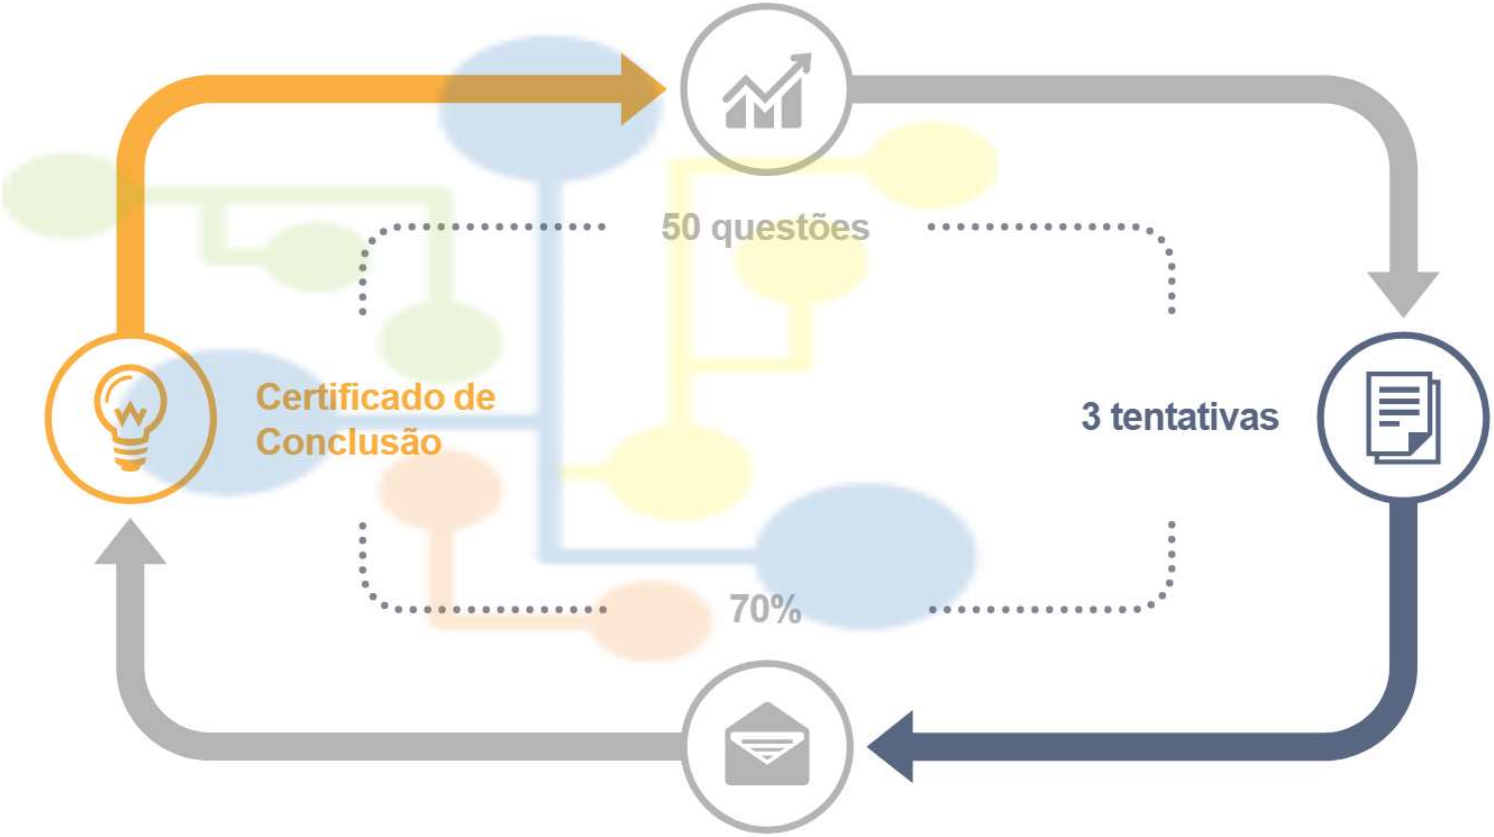

Engenharia de Dados com Hadoop e Spark

Como Obter Sucesso Neste Curso?

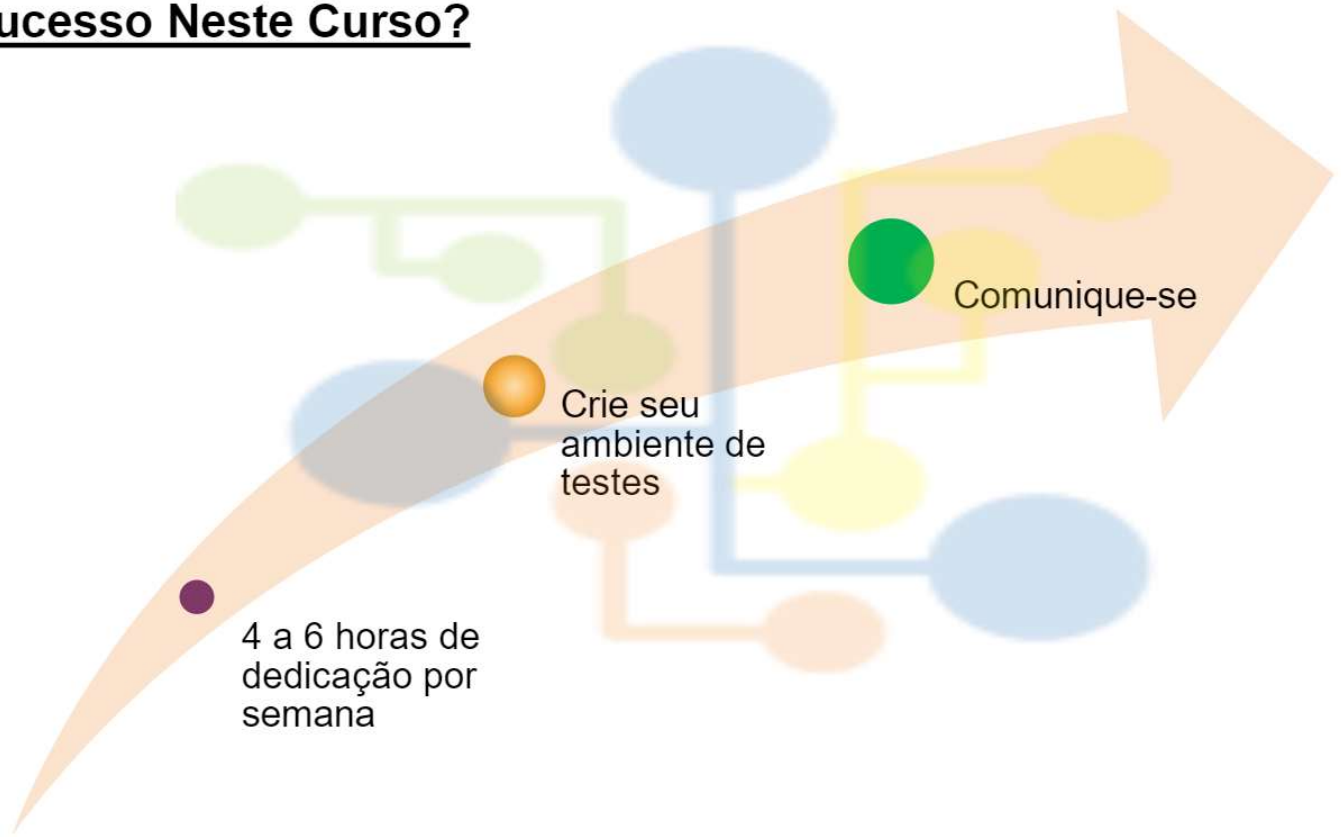

Engenharia de Dados com Hadoop e Spark

Engenharia de Dados com Hadoop e Spark

Engenharia de Dados com Hadoop e Spark

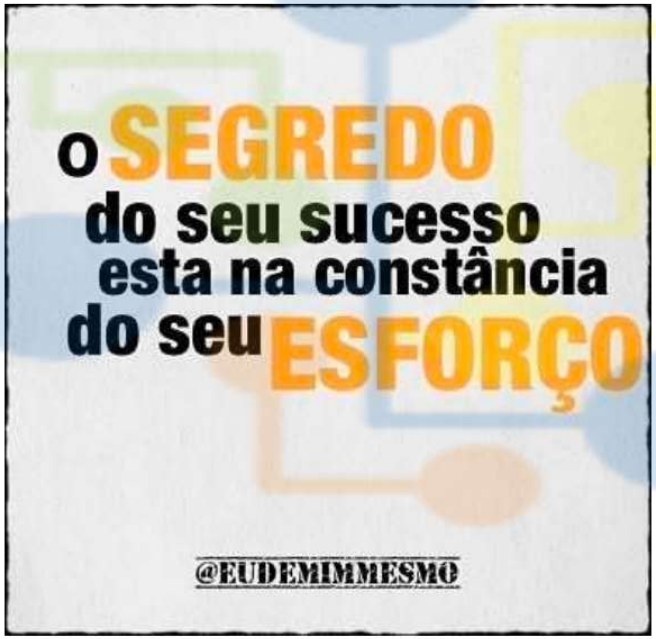

Engenharia de Dados com Hadoop e Spark

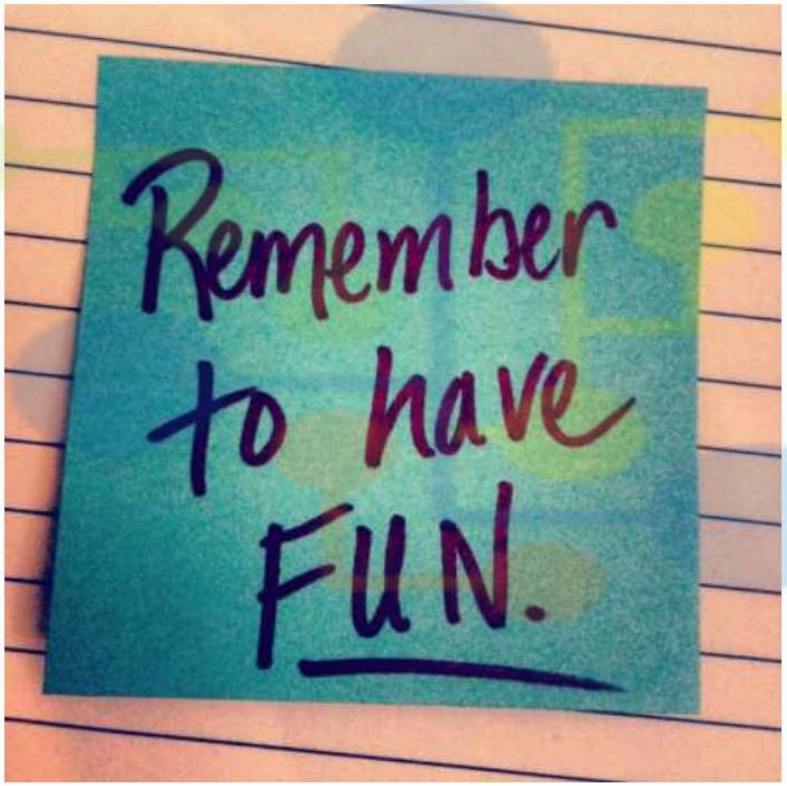

O que é o Apache Hadoop?

O que é o Apache Hadoop?

O que é o Apache Hadoop?

Um dos grandes desafios computacionais da atualidade é armazenar, manipular e analisar, de forma inteligente, a grande quantidade de dados existente.

Sistemas corporativos, sistemas Web, mídias sociais, entre outros, produzem juntos um volume impressionante de dados, alcançando a dimensão de petabytes diários.

O que é o Apache Hadoop?

O que é o Apache Hadoop?

O que é o Apache Hadoop?

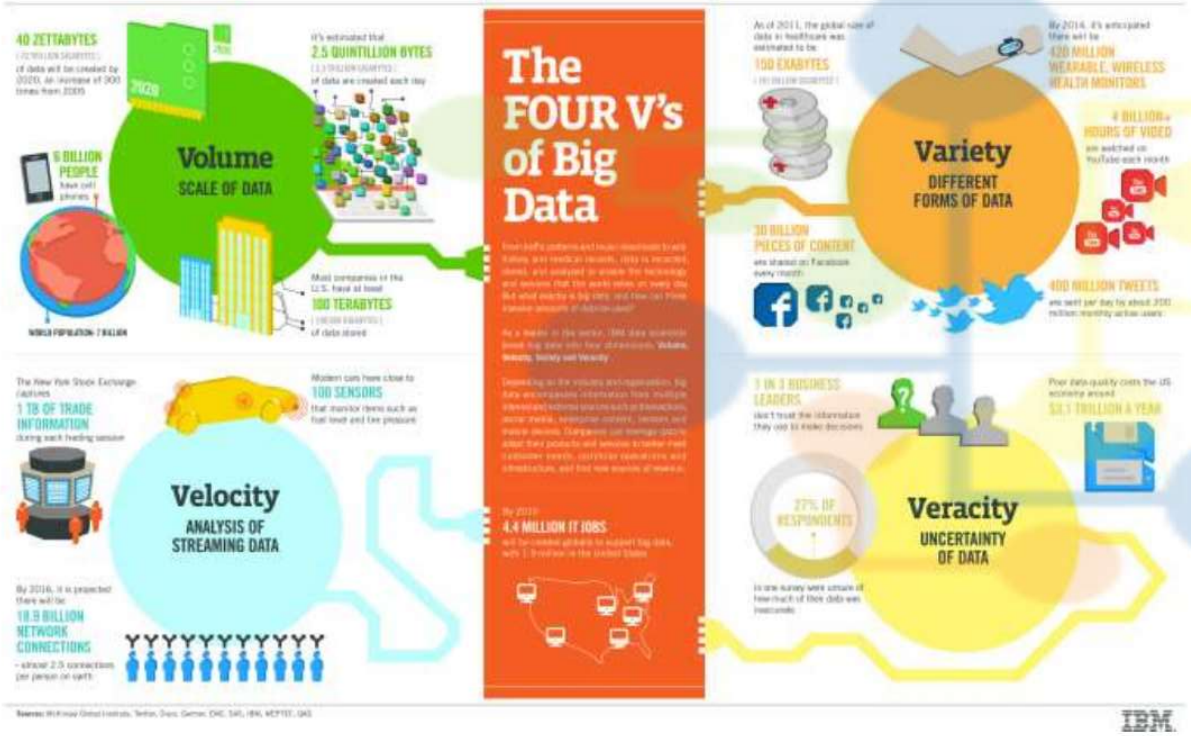

Os 4 V's do Big Data:

- Volume
- Variedade
- Velocidade
- Veracidade

O que é o Apache Hadoop?

O que é o Apache Hadoop?

Computação Paralela

O que é o Apache Hadoop?

Uma Breve História do Apache Hadoop

Hadoop History

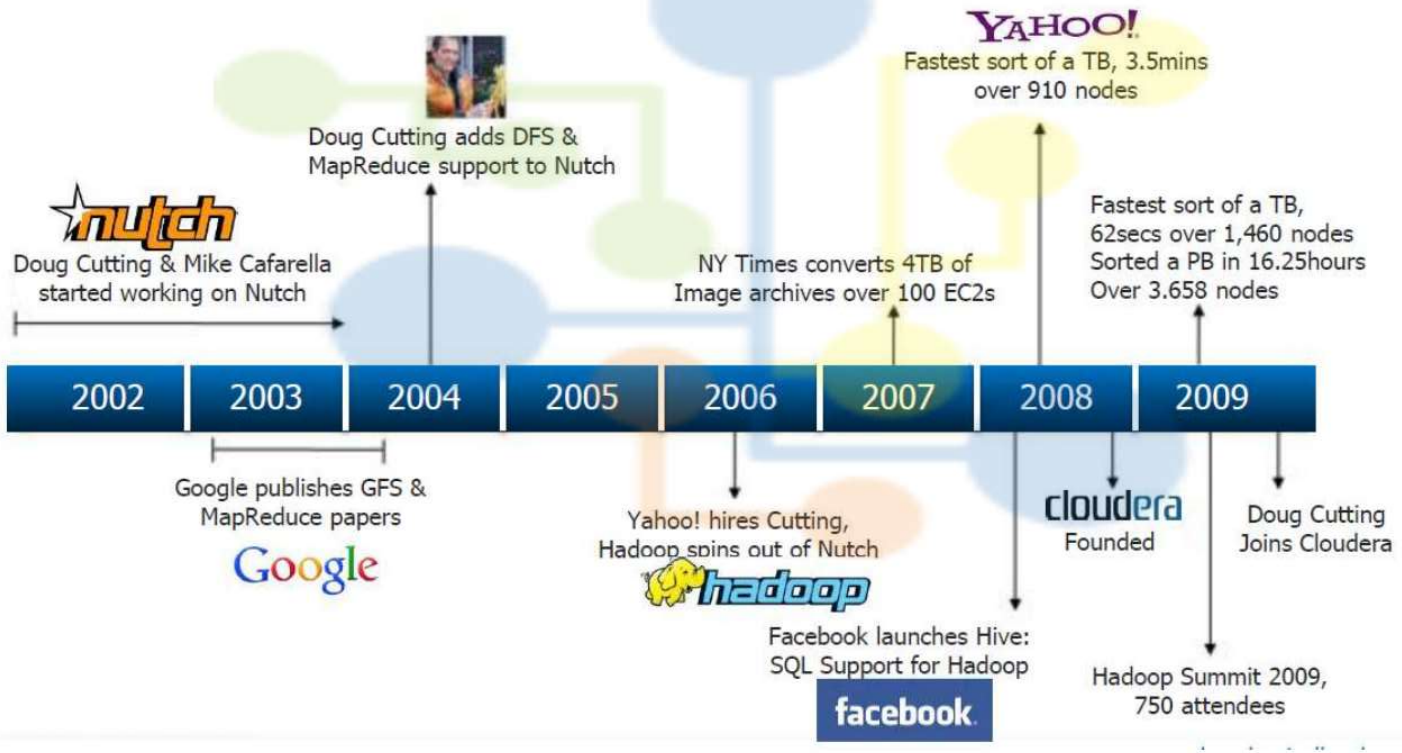

Uma Breve História do Apache Hadoop

Hadoop History

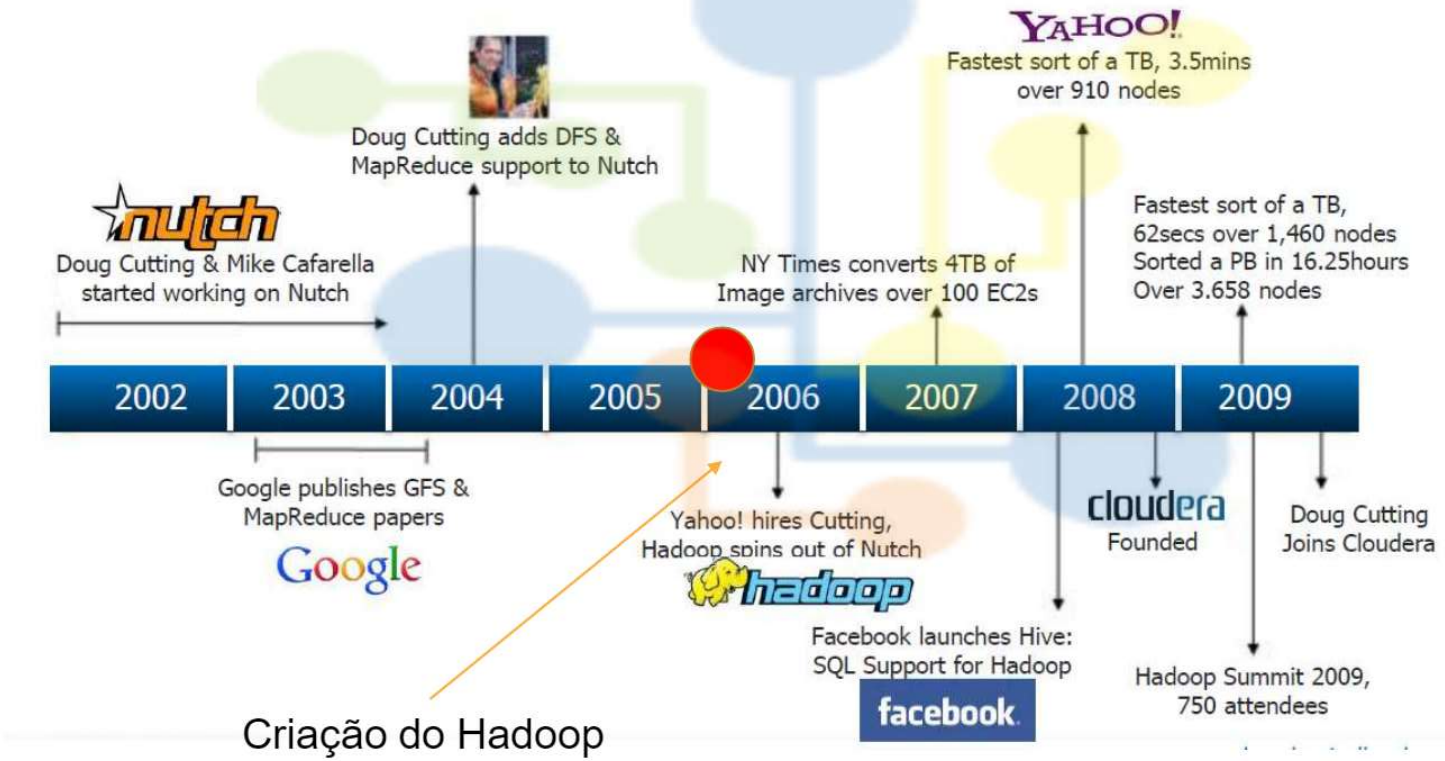

Uma Breve História do Apache Hadoop

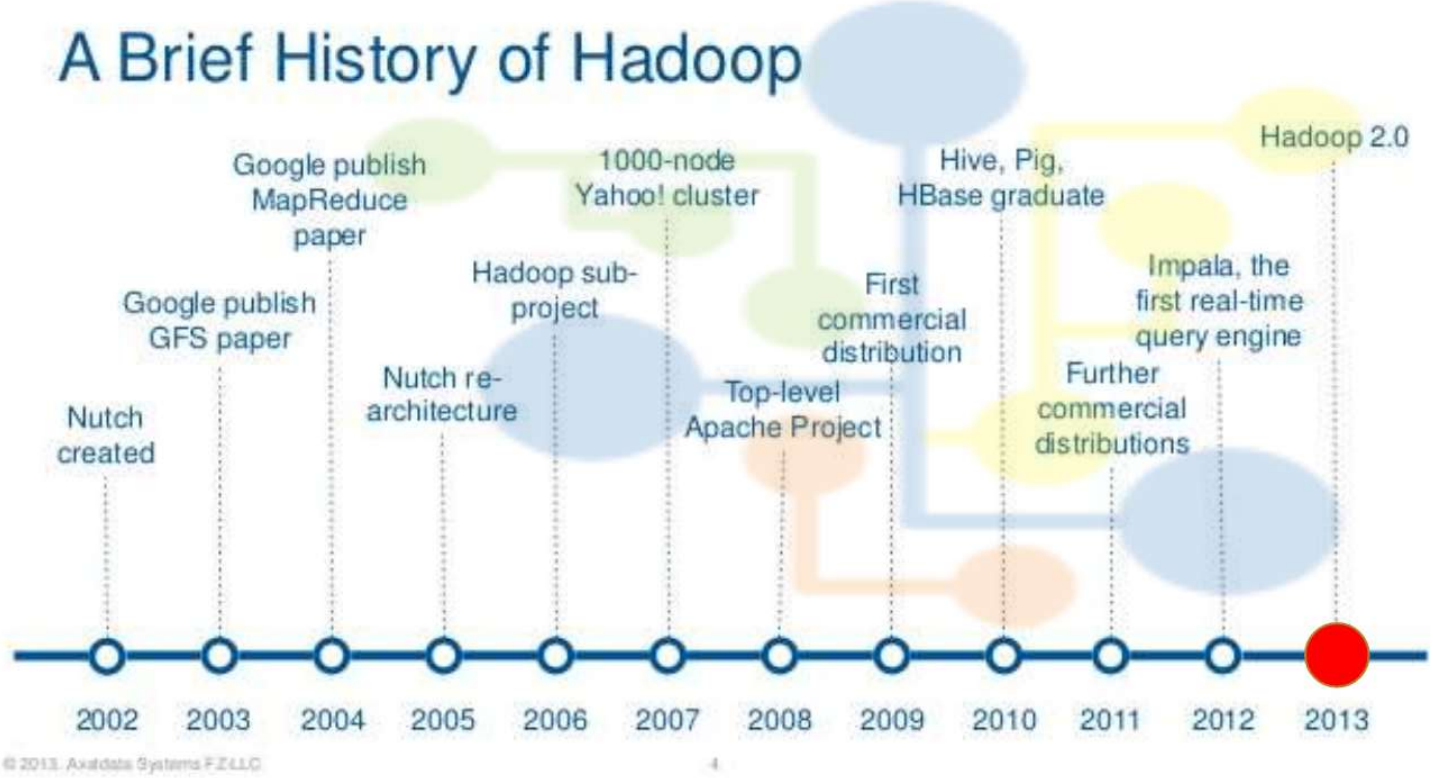

2018
Versão 3.0

2019
Versão 3.2.x

O que é o Hadoop?

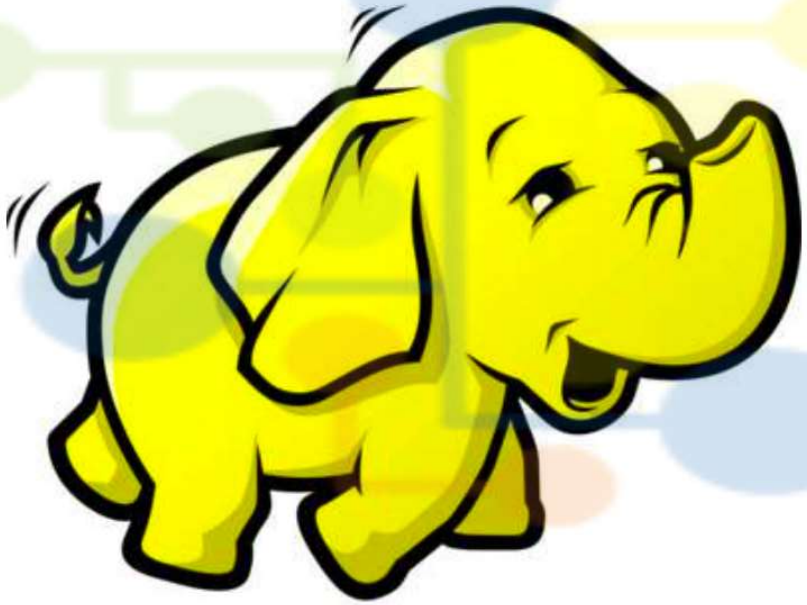

Quais os benefícios para as Empresas ao utilizar o Hadoop?

Benefícios do Hadoop

Benefícios do Hadoop

Open Source

Benefícios do Hadoop

Economia

Benefícios do Hadoop

Escalabilidade

Benefícios do Hadoop

Robustez

Desvantagens do Hadoop

Desvantagens

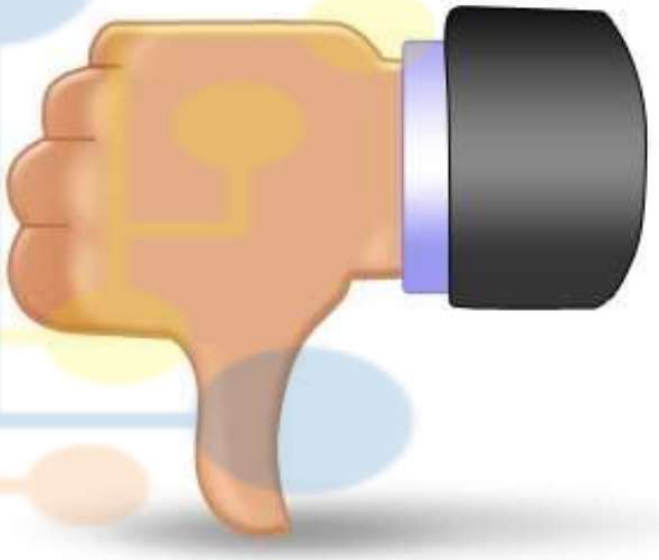

Desvantagens do Hadoop

Desvantagens

- Node Master Único
- Processamento de Arquivos Pequenos
- Muito Processamento em Poucos Dados

Ecossistema Hadoop

Ecossistema Hadoop

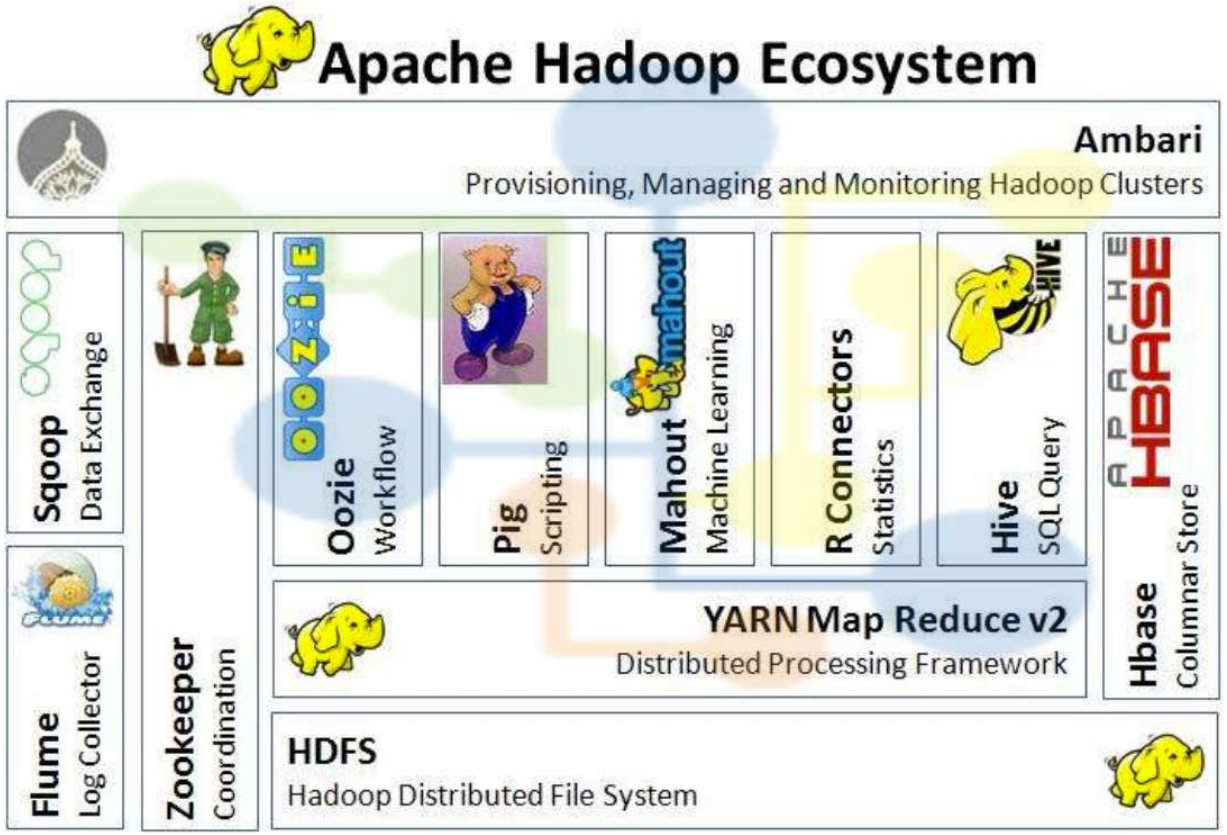

Ecossistema Hadoop

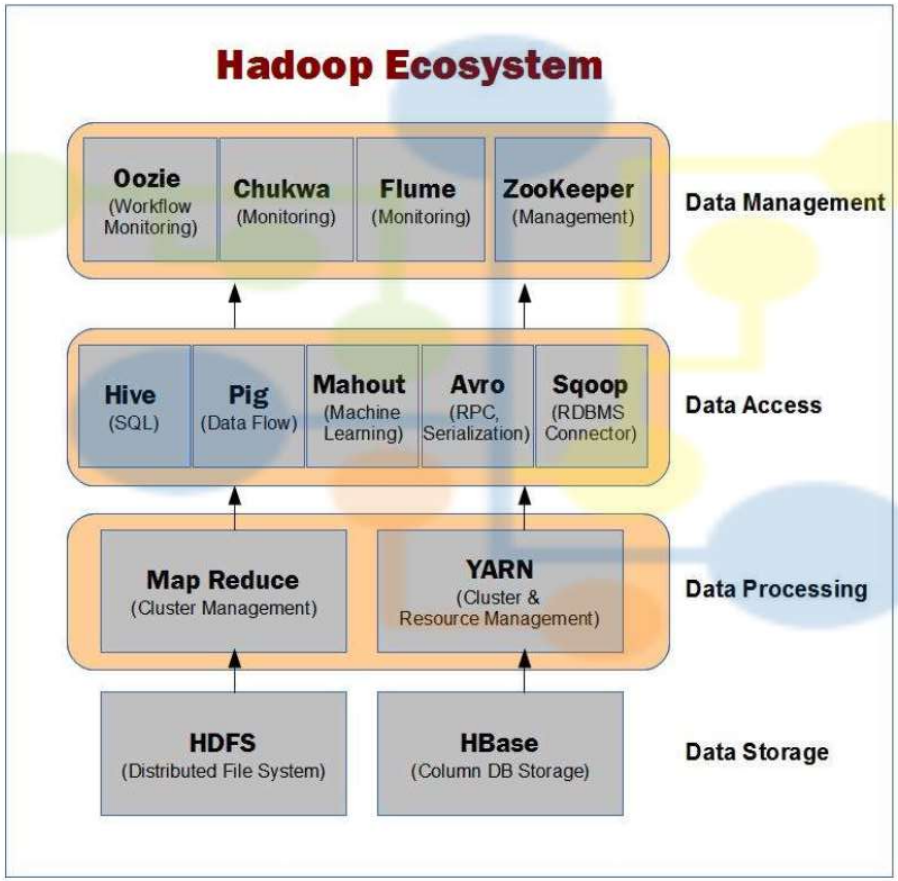

Ecossistema Hadoop

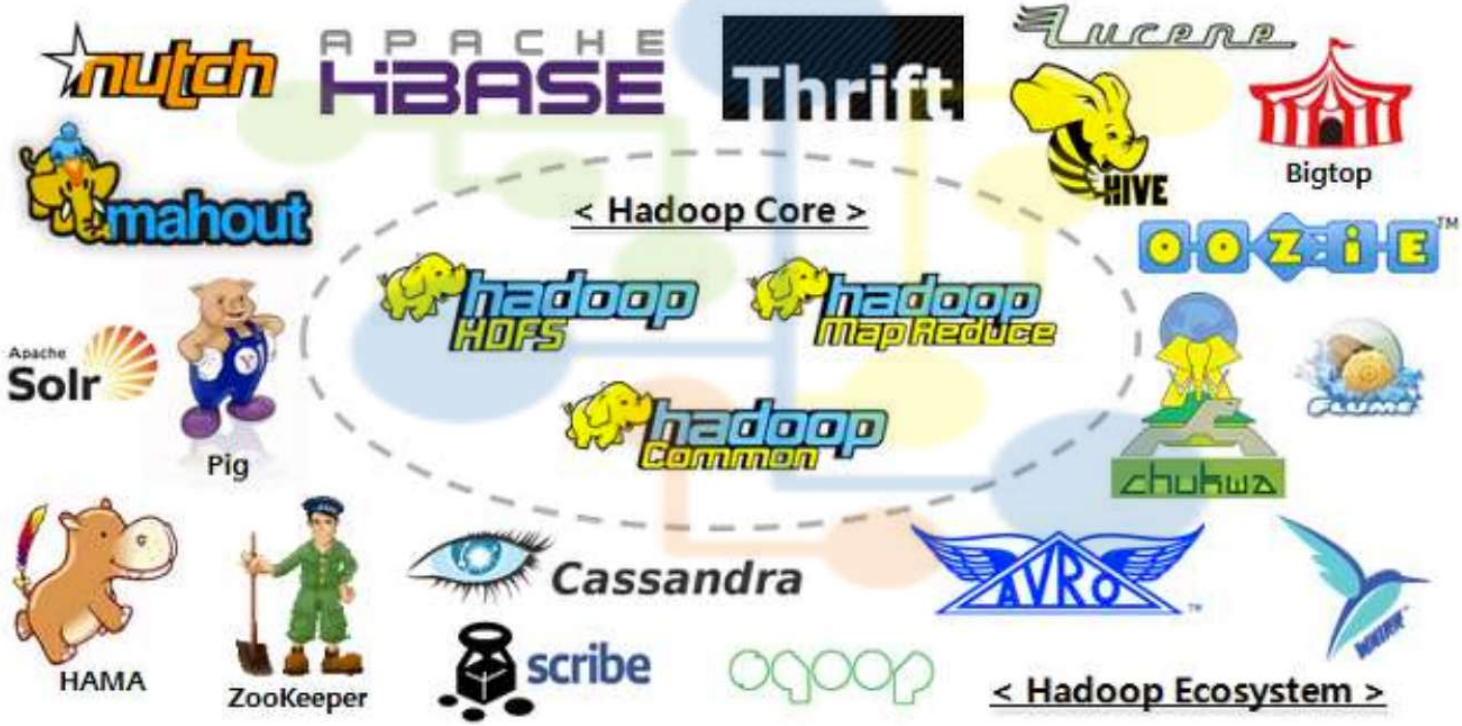

Ecossistema Hadoop

Projetos Principais do Ecossistema Hadoop

- Hadoop YARN
- Hadoop MapReduce
- Hadoop HDFS (Hadoop Distributed File System)

Ecossistema Hadoop

Outros Projetos Importantes

Ecossistema Hadoop

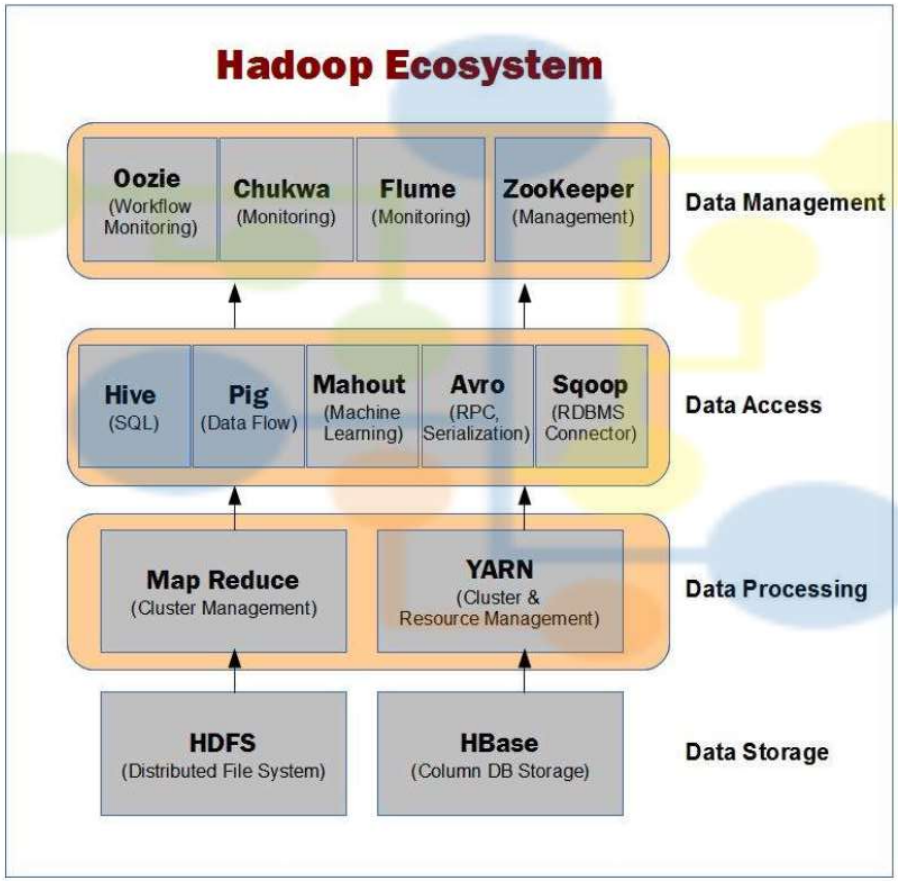

HDFS (Hadoop Distributed File System)
Conceito e Importância

HDFS – Conceito e Importância

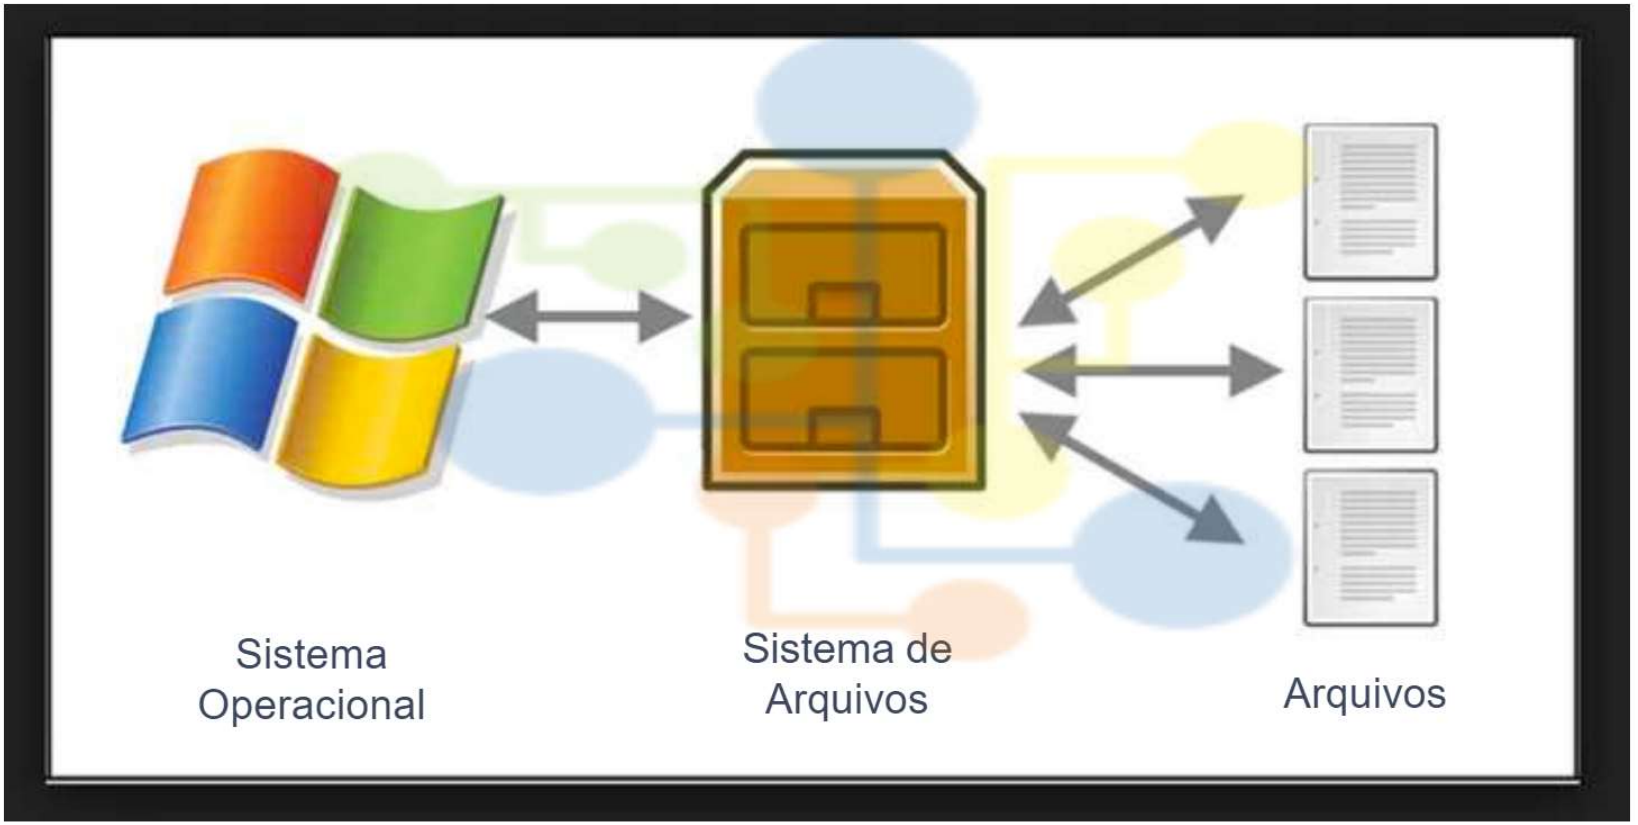

HDFS – Conceito e Importância

Os tipos de Sistemas de Arquivos são:

Tipo	Descrição
`ext2`	Sistema de arquivos padrão do Linux
`ext3`	Sistema de arquivos ext2 melhorado
`reiserfs`	Sistema de arquivos do tipo Journaling
`msdos`	Sistema de aruqivos FAT da Microsoft DOS
`vfat`	Sistema de arquivos FAT-32 do Microsoft Windows
`iso9660`	Sistema de arquivos do CD-ROM
`nfs`	Network File System. Usado par a montar dispositivos em computadores remotos.
`swap`	Sistema de arquivos de troca utilizando para memória virtual.
`proc`	Uma janela especial dentro do Kernel do Linux. Utilizada pelos usuários, programas e utilitários para escrever ou ler parâmetros do Kernel. Geralmente montado no diretório `/proc`.

HDFS – Conceito e Importância

HDFS – Conceito e Importância

Sistema de Arquivos Distribuído

HDFS – Conceito e Importância

- Tolerância a Falhas
- Integridade
- Segurança
- Desempenho
- Consistência

HDFS – Conceito e Importância

Outros Sistemas de Arquivos Distribuídos

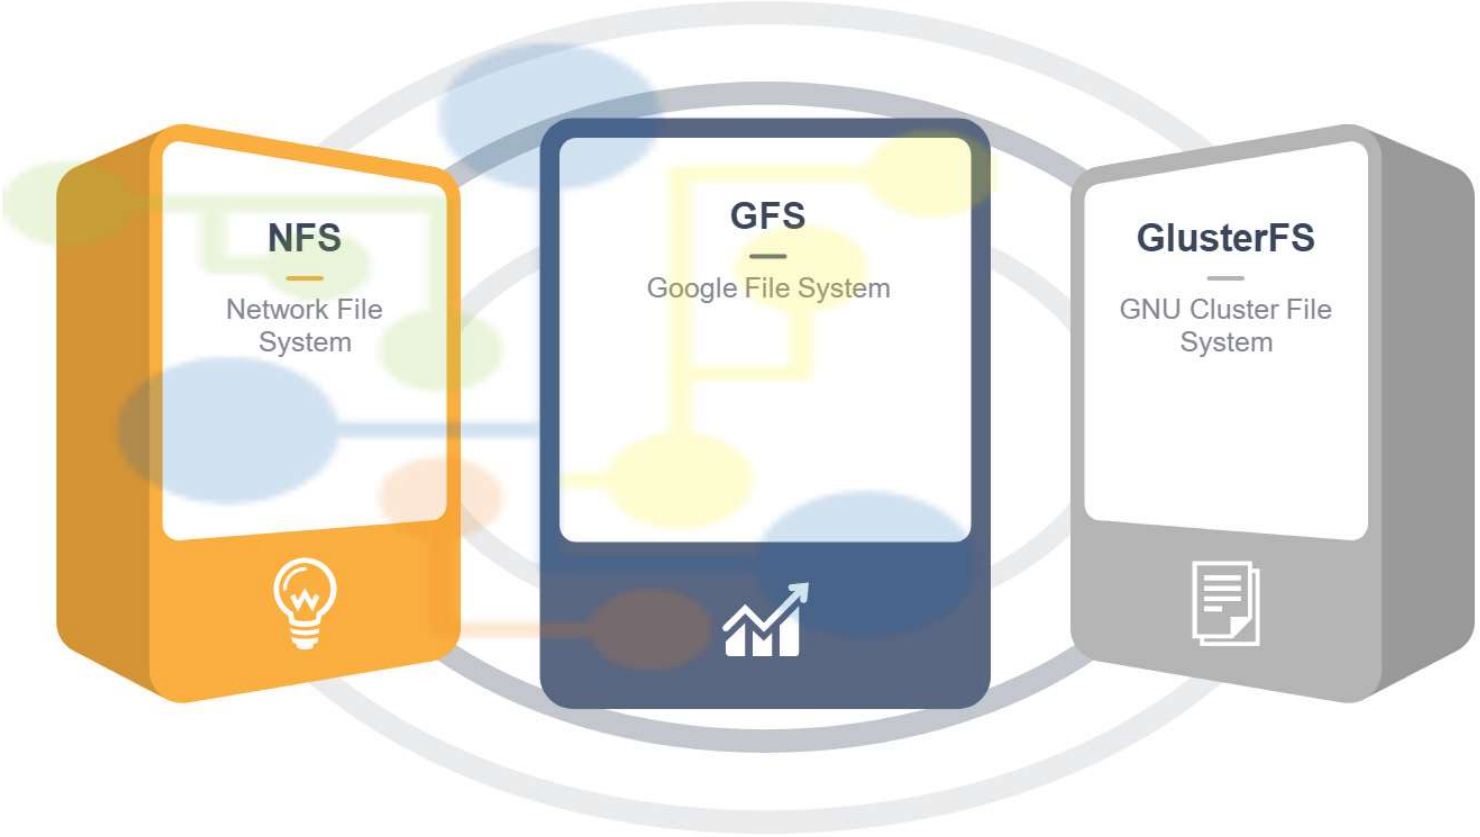

HDFS – Conceito e importância

Hadoop Distributed File System

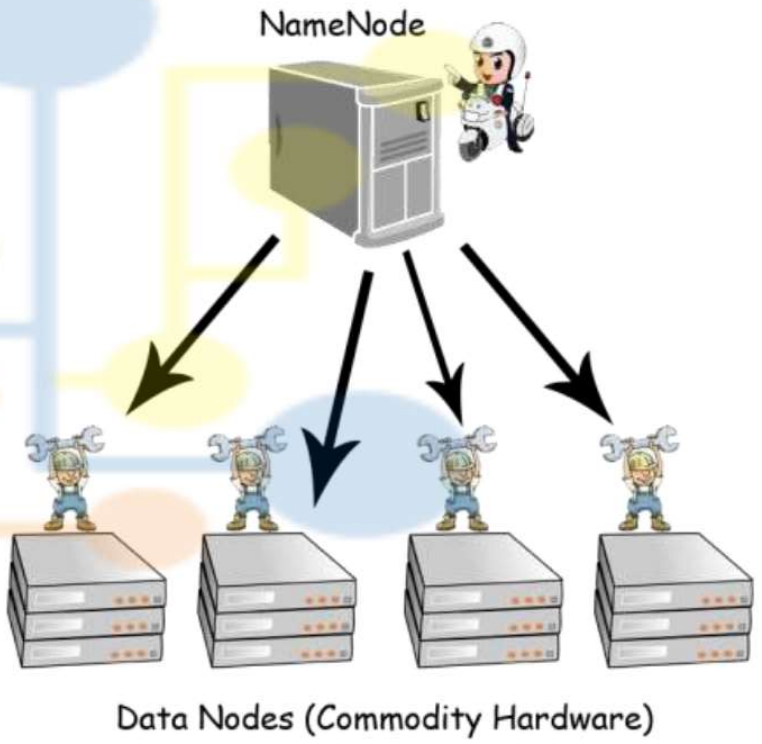

HDFS – Conceito e Importância

Hadoop Distributed File System

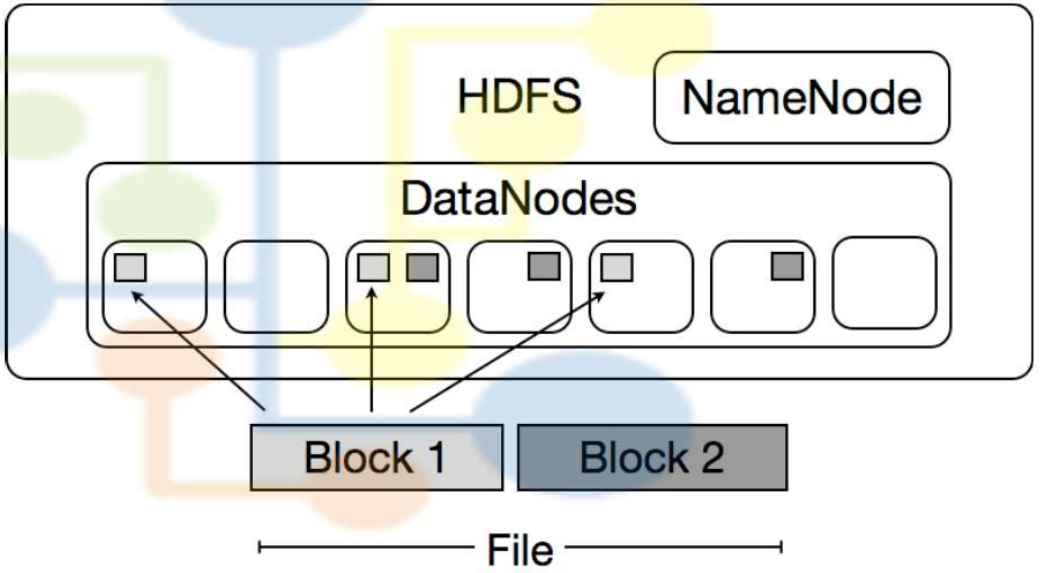

HDFS – Conceito e Importância

Hadoop Distributed File System

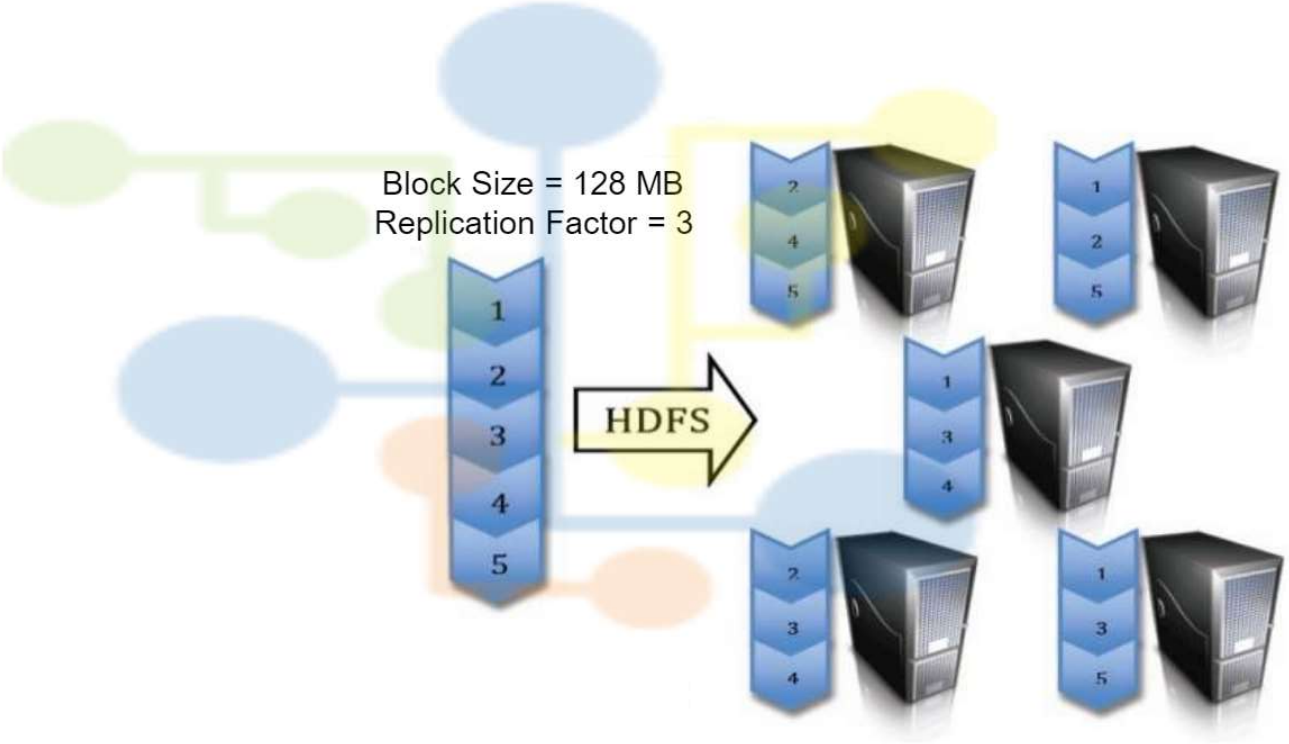

HDFS – Conceito e Importância

O HDFS foi criado para resolver ”Big Problems” e por isso seu funcionamento e arquitetura são próprios para se trabalhar com grandes arquivos de dados e distribuir esses arquivos em blocos ao longo de um cluster de computadores, para que possam ser processados em paralelo.

HDFS (Hadoop Distributed File System)
Arquitetura

HDFS – Arquitetura

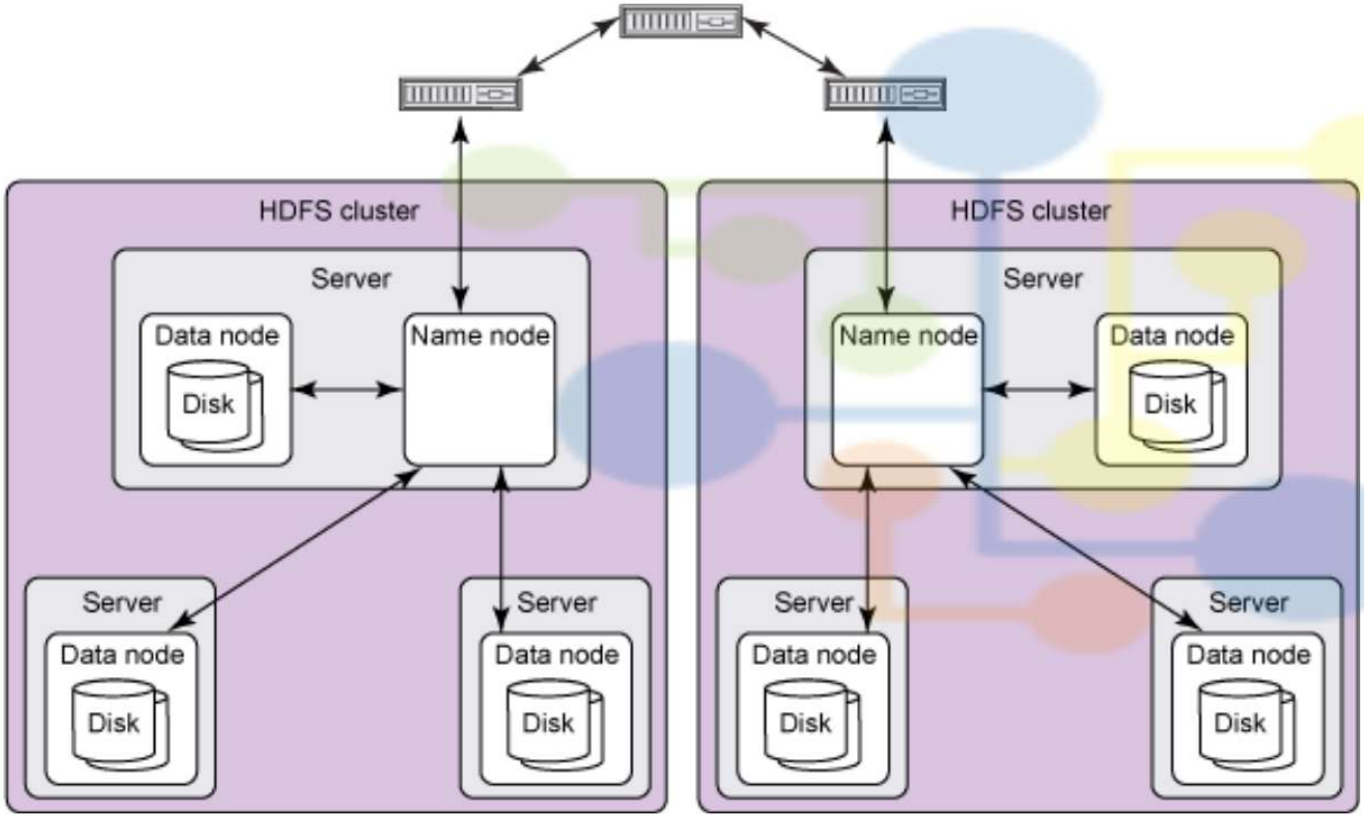

Arquitetura Master/Worker

HDFS – Arquitetura

Arquitetura
Master/Worker

HDFS – Arquitetura

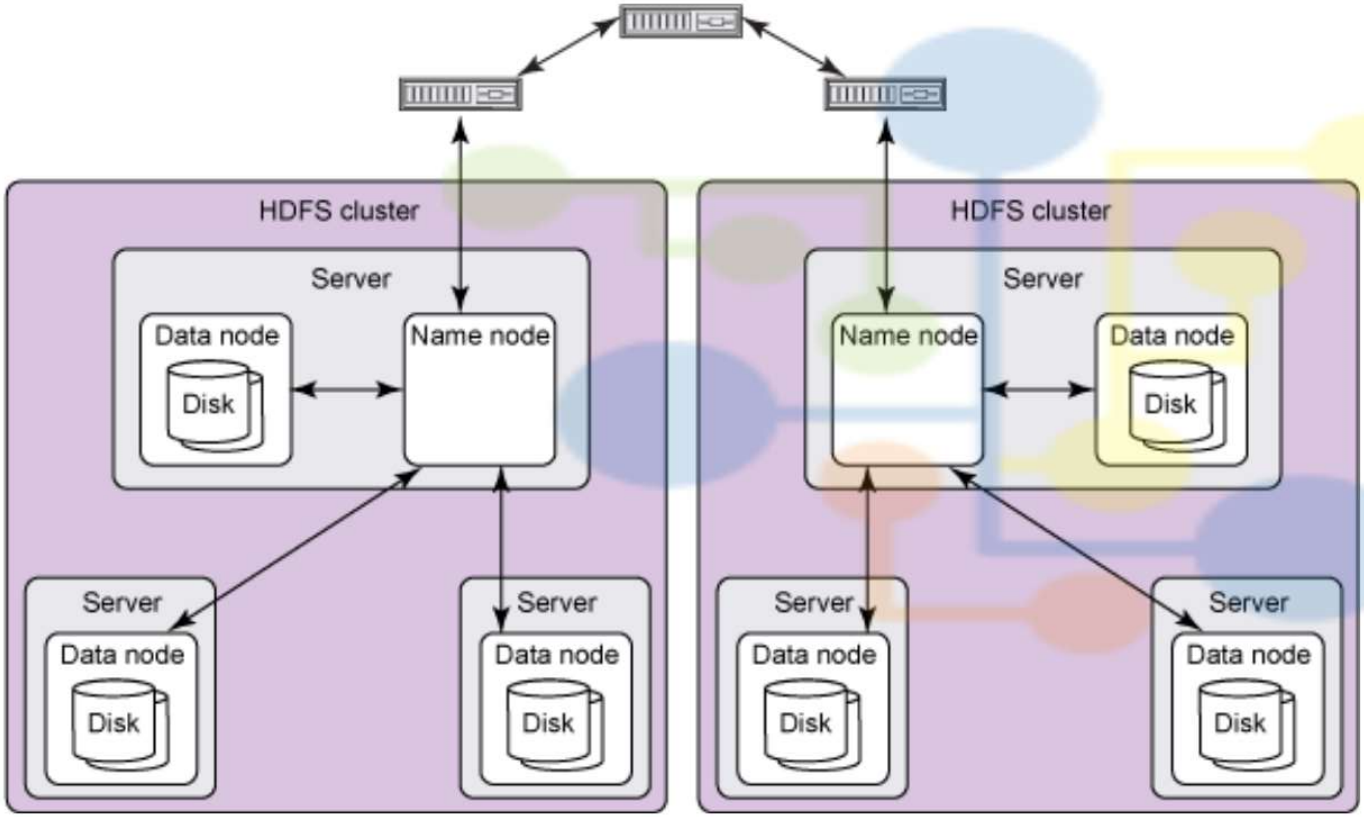

Arquitetura Master/Worker

HDFS – Arquitetura

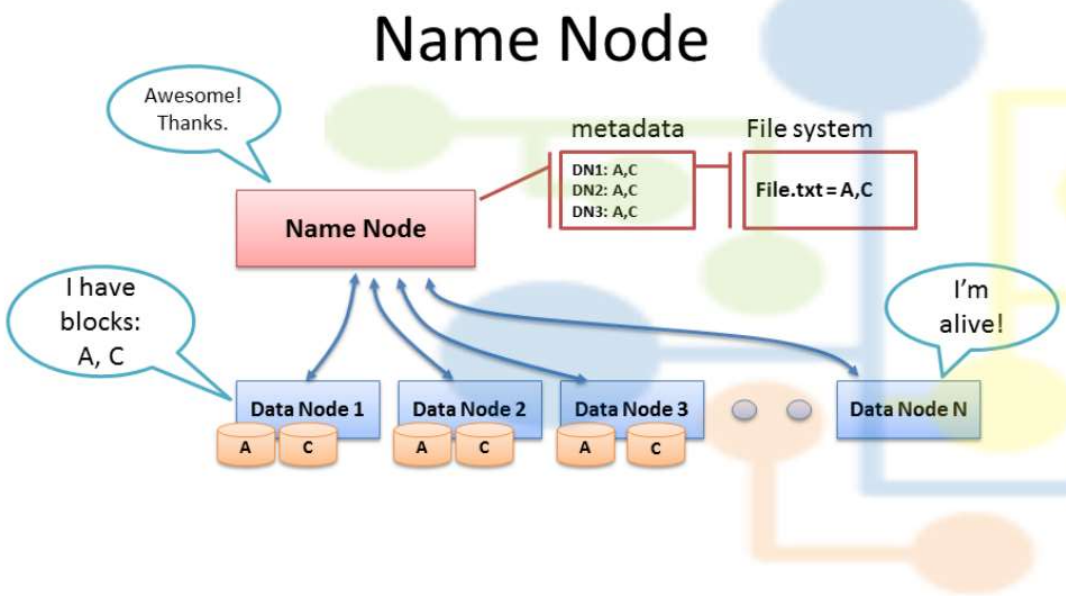

NameNode

- FsImage
- EditLog

HDFS – Arquitetura

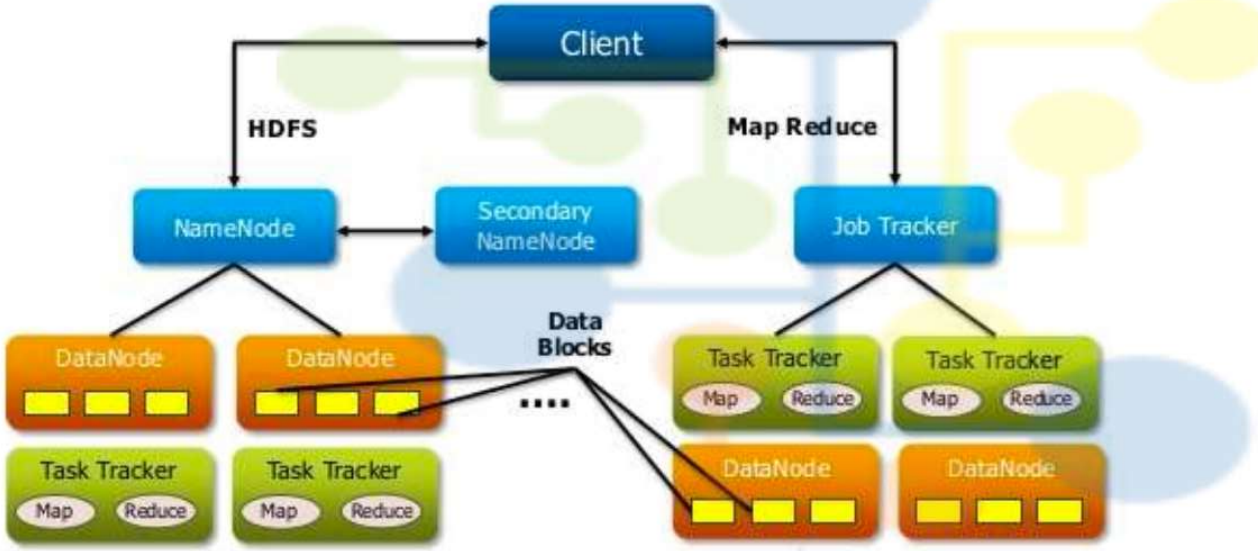

NameNode

- FsImage
- EditLog

HDFS – Arquitetura

Replicação

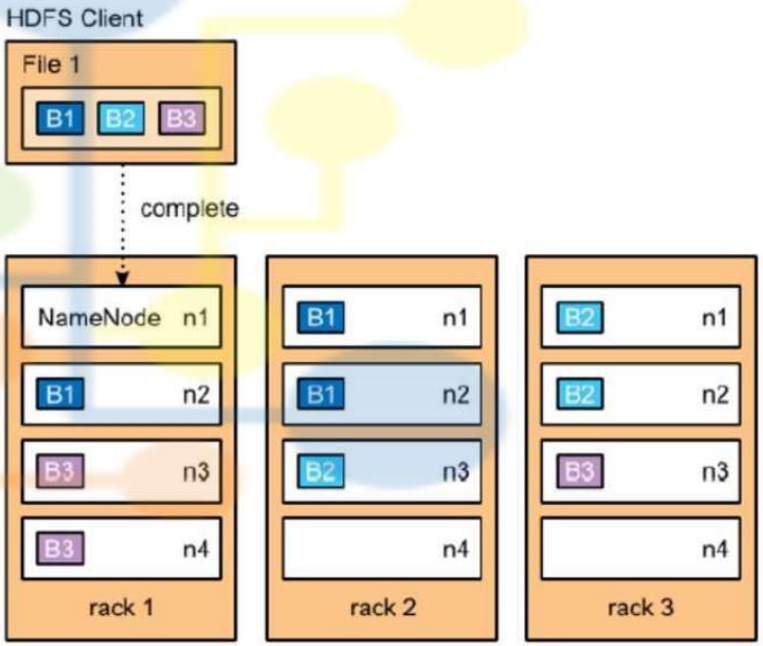

HDFS – Arquitetura

Replicação

Definindo MapReduce

Definindo MapReduce

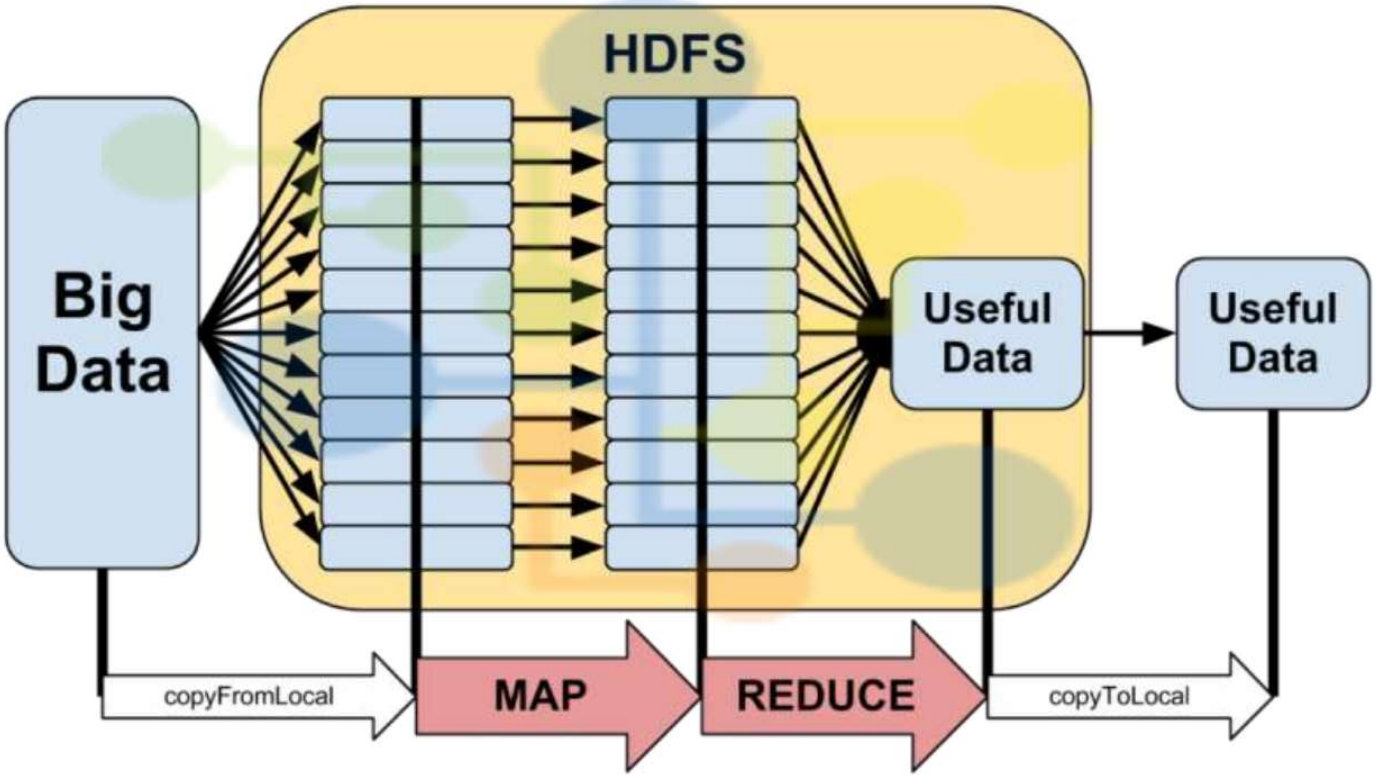

Definindo MapReduce

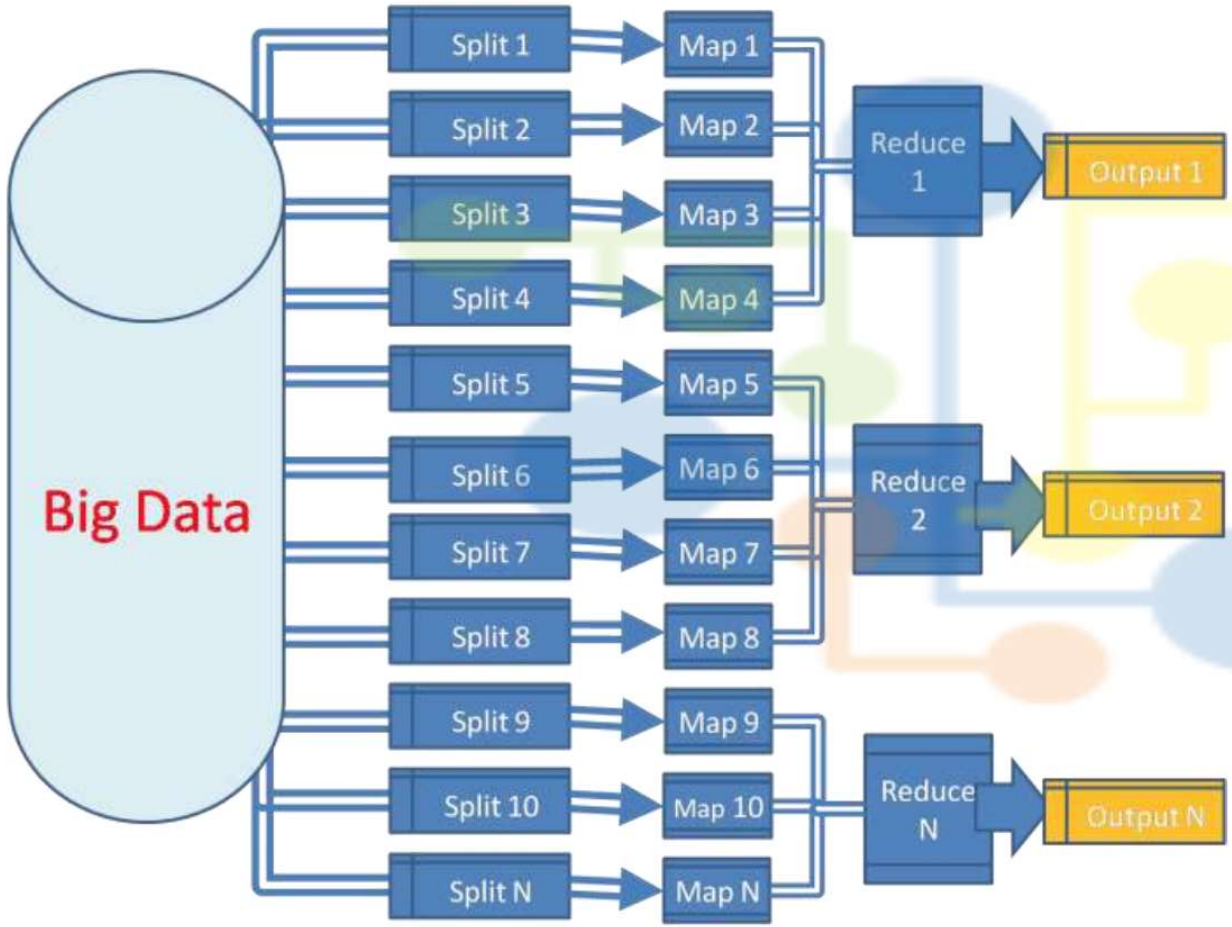

Processamento Paralelo e Distribuído

Definindo MapReduce

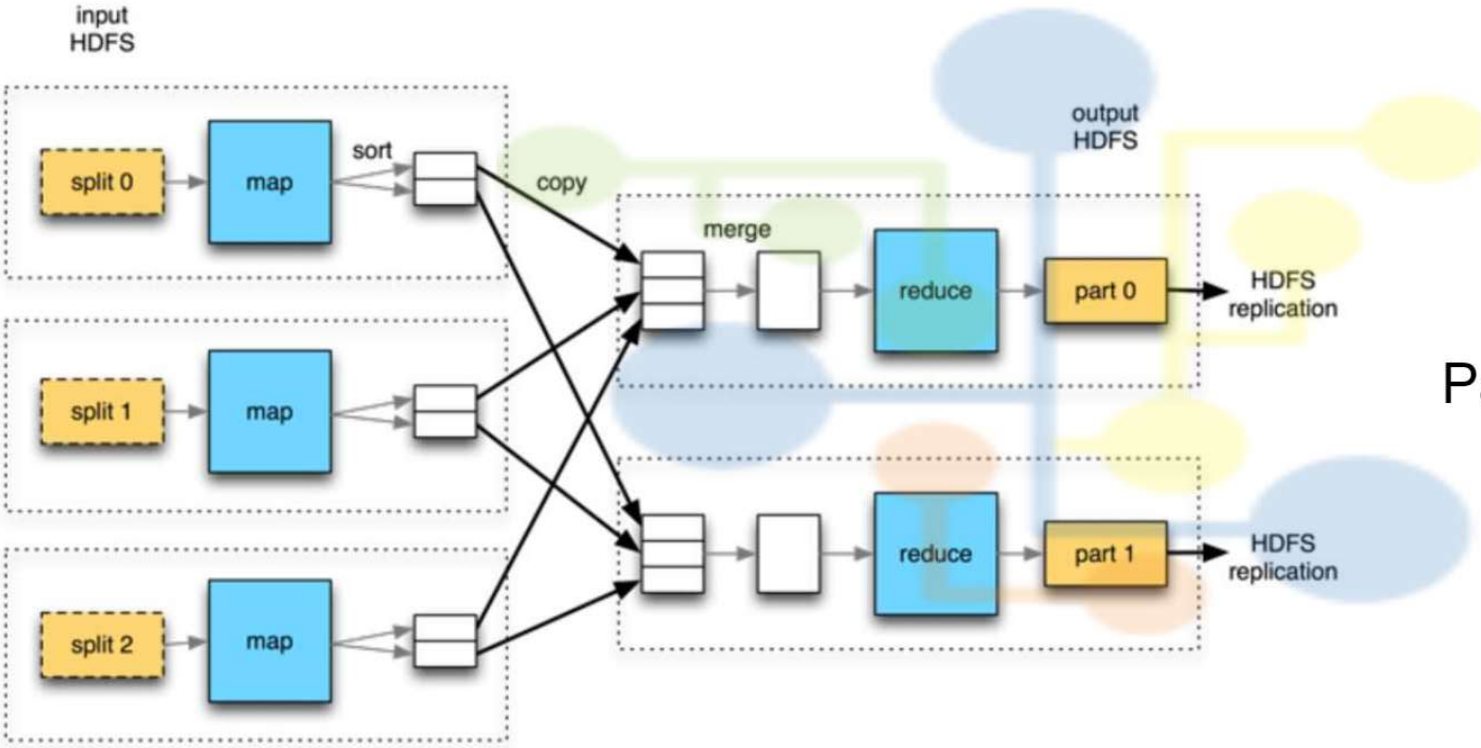

Processamento
Paralelo e Distribuído

Definindo MapReduce

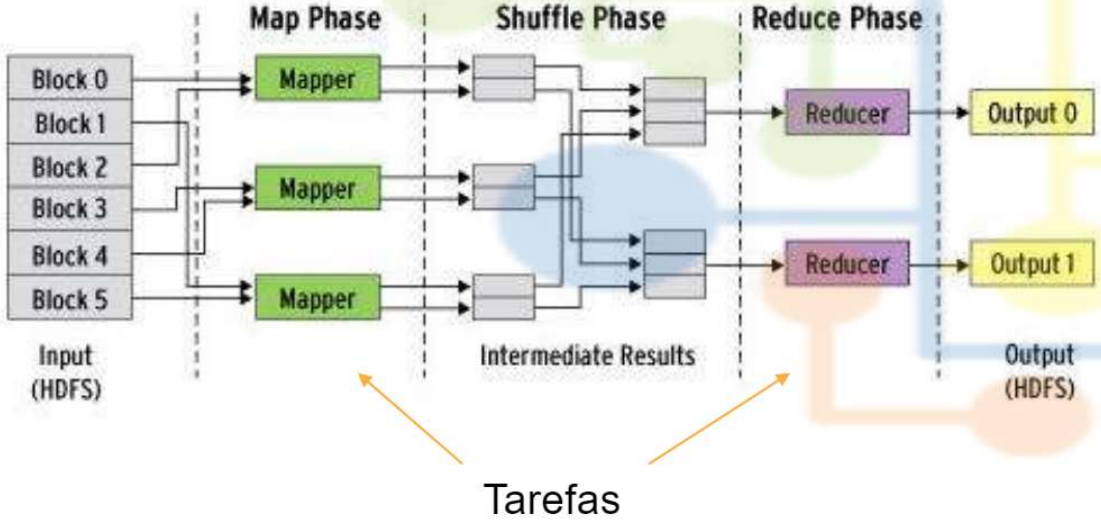

Processamento Paralelo e Distribuído

Hadoop
x
Bancos de Dados Relacionais

Hadoop x Bancos de Dados Relacionais

Bancos de Dados Relacionais

Hadoop x Bancos de Dados Relacionais

RDBMS
Relational Database
Management Systems

Hadoop x Bancos de Dados Relacionais

SGBD's

Gerenciam um ou mais bancos de dados

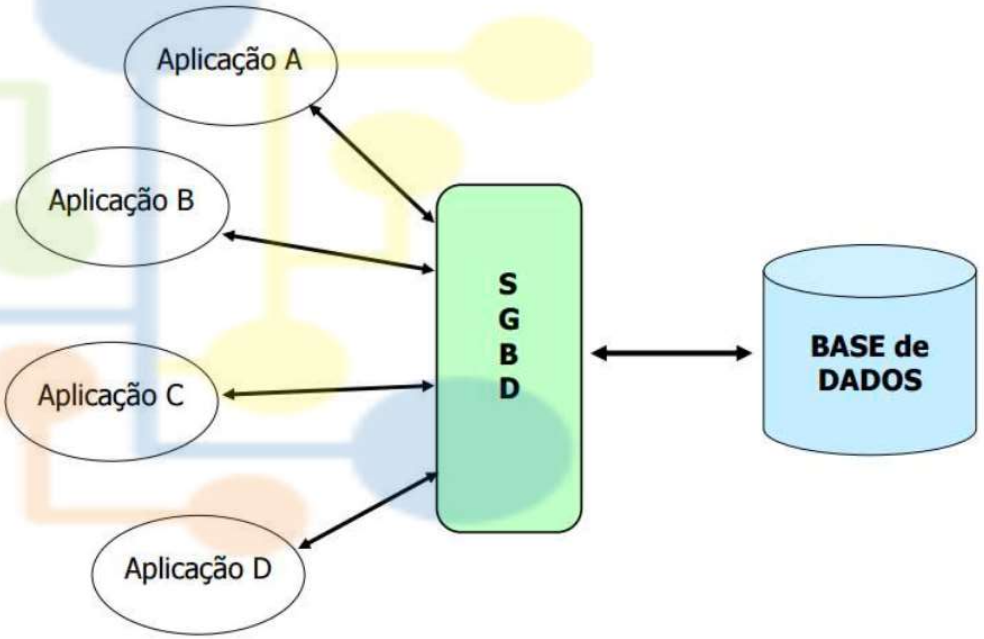

Hadoop x Bancos de Dados Relacionais

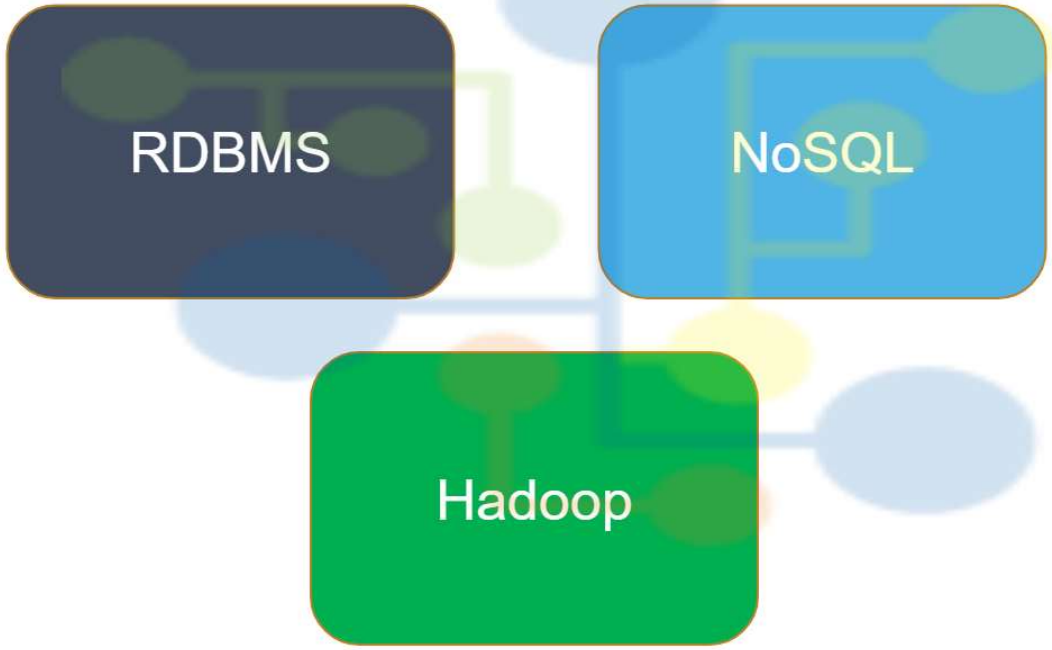

Hadoop x Bancos de Dados Relacionais

Hadoop x Bancos de Dados Relacionais

ACID

Atomicidade
Consistência
Isolamento
Durabilidade

Hadoop x Bancos de Dados Relacionais

Hadoop x Bancos de Dados Relacionais

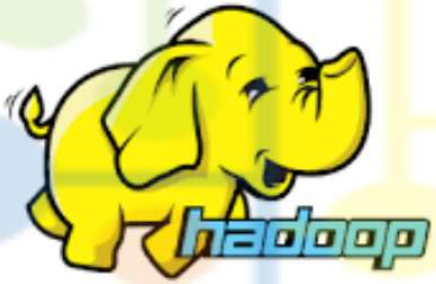

Hadoop x Bancos de Dados Relacionais

Hadoop → Grandes volumes de dados (estruturados ou não estruturados)
RDBMS → Dados transacionais (dados estruturados)

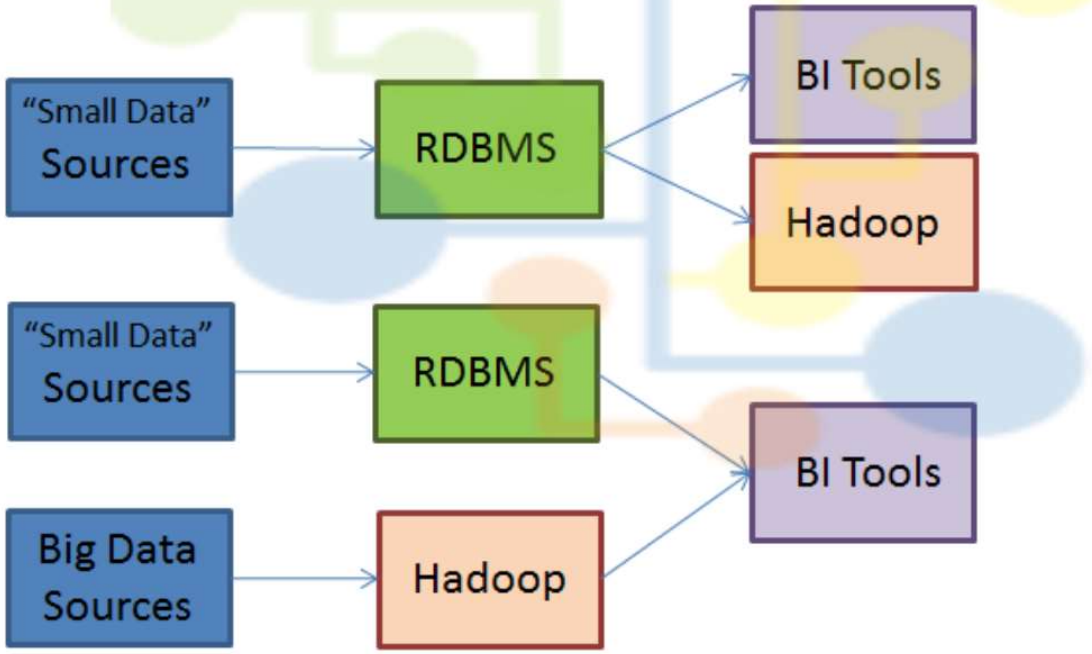

Hadoop x Bancos de Dados Relacionais

Hadoop x Bancos de Dados Relacionais

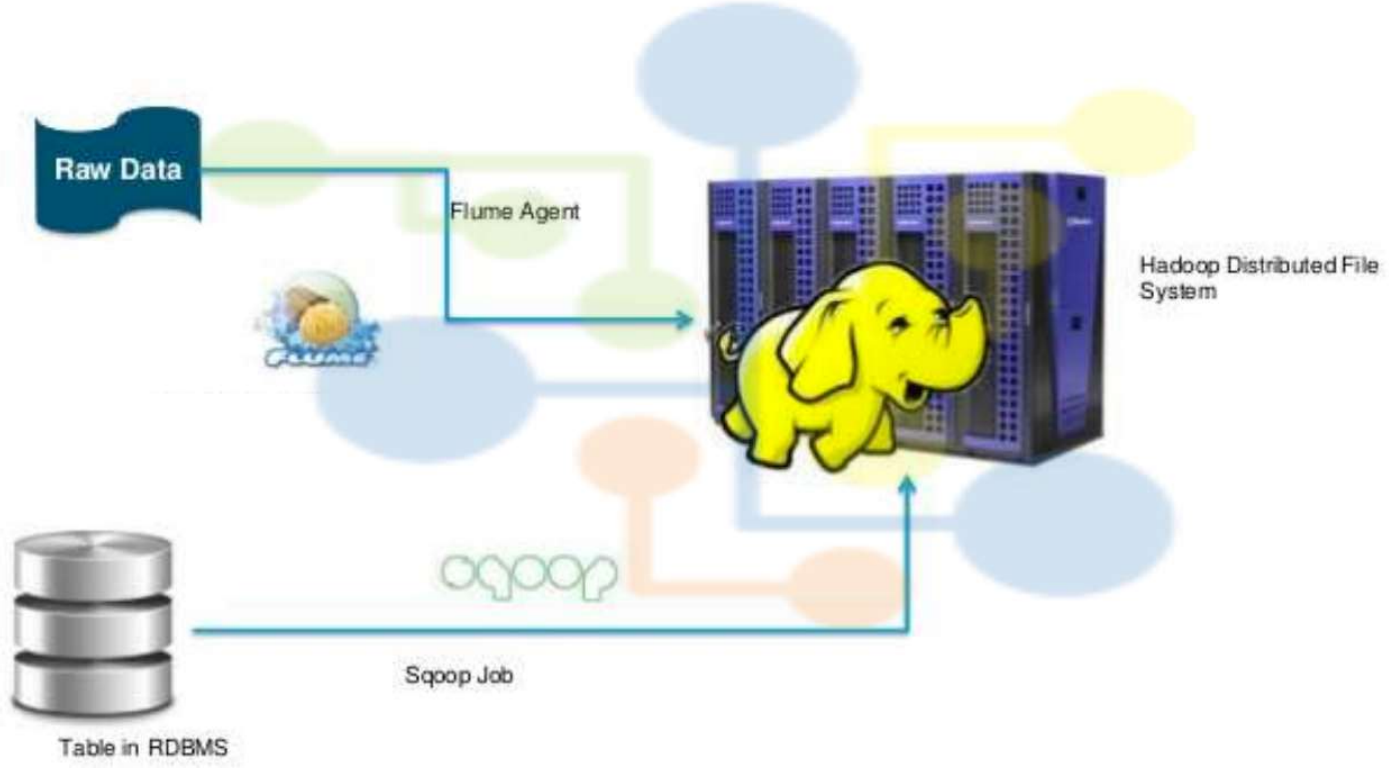

Hadoop x Bancos de Dados Relacionais

Hadoop processa dados em batch. Consequentemente, ele não deve ser usado para processar dados transacionais. Mas o Hadoop pode resolver muitos outros tipos de problemas relacionados ao Big Data.

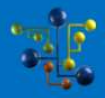

Obrigado